

本周学习进展（2025.5.25 - 2025.5.31）

1. 阅读论文 Drive-KD: Mitigating Cross-Capability Gradient Conflicts in Multi-Teacher Distillation (arXiv-2026): 文章针对大型视觉语言模型在自动驾驶中部署成本高，且多任务联合蒸馏面临监督信号选择盲目与任务间梯度冲突的问题，提出一套多教师蒸馏解决方案：①将驾驶任务解构为“感知-推理-规划”三元时序能力，弃用发散的输出预测概率，提取更加稳定的层特定注意力图作为蒸馏信号；②针对不同能力定制网络层对齐策略，分别提取教师的第一层、中间滑动层组以及倒数第二层的跨模态注意力来指导学生模型；③引入双阶段非对称梯度投影机制，在单能力内部以硬标签监督梯度为绝对锚点，非对称地剪除软标签蒸馏梯度中的冲突正交分量；④在跨能力层面，对净化后的各能力特征梯度进行随机洗牌，并执行两两对称投影消除负内积，从而彻底化解多任务间的相互干扰，实现小模型的高效压缩与规划能力的提升。

2. 本周新增对于数据集 ISBI2016 的支持，但是经过多轮调参后，发现现有方法进能够在数据集 BUSI 上起效果，在其他数据集上没有效果或者负效果。目前负责师生对齐蒸馏的模块越来越复杂，但是没有带来好的效果，接下来准备深入思考师生如何进行对齐的这个问题。

本周学习进展（2025.5.18 - 2025.5.24）

1. 对已有的研究梯度冲突的论文进行梳理和归类：
- (1) 作用在优化层（梯度手术类方法）：
- ① Gradient Surgery for Multi-Task Learning(NeurIPS-2020)
 - ② Just Pick a Sign: Optimizing Deep Multitask Models with Gradient Sign Dropout(NeurIPS-2020)
 - ③ Conflict-Averse Gradient Descent for Multi-Task Learning(NeurIPS-2021)
 - ④ Cross-Attention Gradient Transplantation (CAGT): Mitigating Gradient Conflict in Multi-Task Learning Through Cross-Blockwise Attention(Workshop@ICLR-2026)
 - ⑤ Drive-KD: Mitigating Cross-Capability Gradient Conflicts in Multi-Teacher Distillation (arXiv-2026)
- (2) 作用在目标层（权重动态调节类方法）：
- ① GradNorm: Gradient Normalization for Adaptive Loss Balancing in Deep Multitask Networks(ICML-2018)
 - ② Multi-Task Learning as Multi-Objective Optimization(NeurIPS-2018)
 - ③ Student Customized Knowledge Distillation: Bridging the Gap Between Student and Teacher(ICCV-2021)
 - ④ Multi-Task Learning as a Bargaining Game(ICML-2022)
 - ⑤ MoKD: Multi-Task Optimization for Knowledge Distillation(arXiv-2025)

⑥ Two Losses, One Goal: Balancing Conflict Gradients for Semi-supervised Semantic Segmentation(ICCV-2025)

⑦ DeepKD: A Deeply Decoupled and Denoised Knowledge Distillation Trainer(NeurIPS-2025)

⑧ PACED: Distillation at the Frontier of Student Competence (arXiv-2026)

⑨ Dynamic Trade-off Optimization for Knowledge Distillation(ICLR-2026)

(3) 作用在架构层（自适应结构调整类方法）：

① Recon: Reducing Conflicting Gradients from the Root for Multi-Task Learning(ICLR-2023)

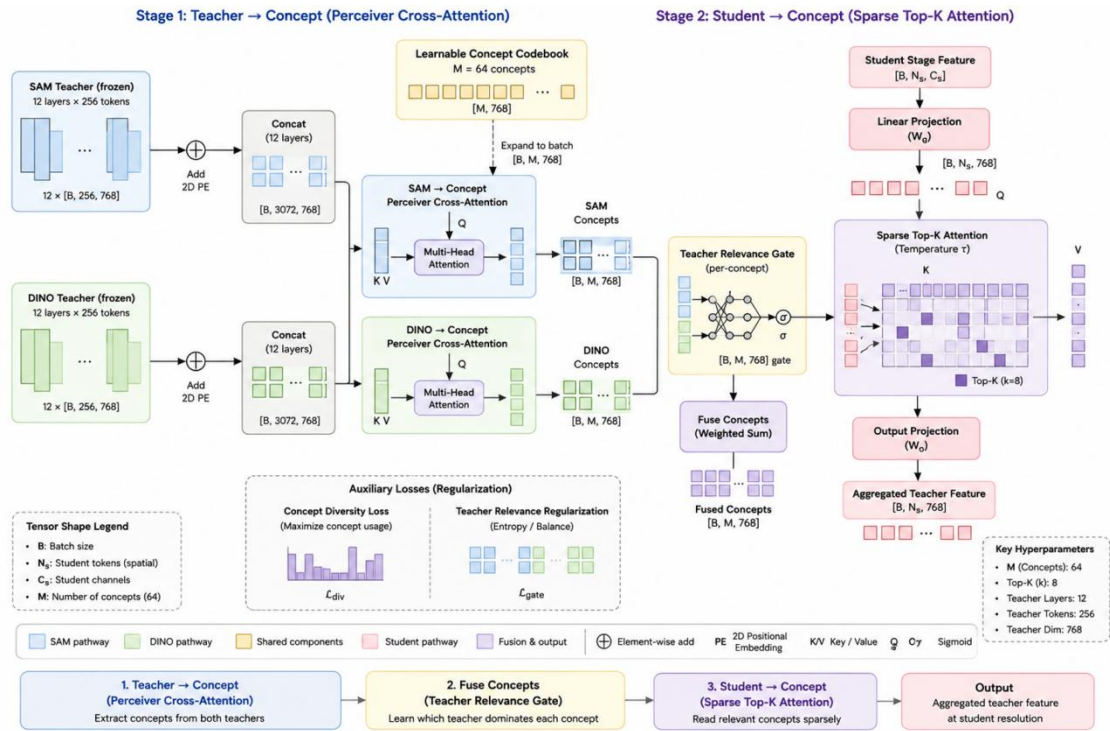
② GradRoute: Gradient-Conflict Resolution in Multi-Task VLA Fine-Tuning (arXiv-2025)

③ Resolving Token-Space Gradient Conflicts: Token Space Manipulation for Transformer-Based Multi-Task Learning(ICCV-2025)

④ Dual-Head Knowledge Distillation: Enhancing Logits Utilization with an Auxiliary Head(KDD-2025)

2. 由于经过多教师蒸馏训练的学生模型 **swin-unet** 在数据集 **ACDC** 和 **Synapse** 上的表现一直无法超越仅用任务训练的模型，怀疑是学生模型的架构较小，没有足够的参数容纳多教师的知识，于是增大了学生模型架构重新进行了实验。

3. 之前师生对齐方式较为简单，针对这一问题，重新设计了师生对齐的模块，该模块通过在教师特征上构建共享概念向量实现跨教师知识整合：**SAM-Med2D** 和 **MedDINOv3** 先在各自概念空间生成教师概念，再经门控融合后由学生通过稀疏 **top-k** 注意力读取。



4. 本周增大了学生模型的容量，并且对新设计的模块进行了消融实验，发现我们方法在三个数据集上的各项指标已经较为接近或者小幅超越直接使用任务训练，接下来我会继续对模块进行改进，提高指标表现。

Method	BUSI		ACDC		Synapse	
	Dice↑	HD95↓	Dice↑	HD95↓	Dice↑	HD95↓
<i>Baselines</i>						
SAM-Med2D	0.718	23.0	0.793	2.0	0.845	4.8
MedDINOv3	0.599	97.3	0.806	2.6	0.719	39.8
Swin-Unet	0.848 ± 0.017	33.2 ± 6.1	0.890 ± 0.001	2.3 ± 0.6	0.783 ± 0.004	23.7 ± 3.4
<i>Multi-teacher distillation (3 seeds, B=8)</i>						
CA (w/o CAGT)	0.844 ± 0.007	33.0 ± 2.2	0.890 ± 0.001	2.5 ± 1.3	0.784 ± 0.001	19.8 ± 0.8
CA (w/ CAGT)	0.843 ± 0.003	33.7 ± 4.7	0.887 ± 0.003	2.8 ± 0.9	0.786 ± 0.004	19.6 ± 0.7
MoSCE (w/o CAGT)	0.844 ± 0.002	31.2 ± 1.8	0.890 ± 0.001	1.5 ± 0.1	0.781 ± 0.008	21.4 ± 1.2
MoSCE (w/ CAGT)	0.849 ± 0.013	33.1 ± 6.3	0.887 ± 0.001	2.1 ± 0.1	0.777 ± 0.002	22.7 ± 2.6

本周学习进展（2025.5.11 - 2025.5.17）

1. 本周已经将教师特征聚合的方式修改为交叉注意力，学生的阶段性特征为 `query`，从全部 12 层教师特征中动态选择最有信息量的层和空间位置进行聚合，取代了旧方案中连续 3 层固定平均的静态聚合方式。该方法效果比简单平均好，但是仍然不如使用任务单独训练。

2. CAGT 模块通过独立获取 Task、SAM、DINO 三路梯度，并对 SAM、DINO 梯度是否与 task 梯度方向冲突进行检测，对于冲突的梯度块，使用交叉注意力机制，以冲突的 teacher 梯度块为 `query`，task 和另一 teacher 为 `key` 和 `value`，对冲突的梯度块进行重建，按比例和原始梯度混合，输出最终梯度。该方法最终在数据集 BUSI 上取得了最好的指标，在其他数据集上的表现还不如任务单独训练。

Method	BUSI		ACDC		Synapse	
	Dice↑	HD95↓	Dice↑	HD95↓	Dice↑	HD95↓
<i>Baselines</i>						
SAM-Med2D	0.718	23.0	0.793	2.0	0.845	4.8
MedDINOv3	0.599	97.3	0.806	2.6	0.719	39.8
Swin-Unet (task only)	0.812	44.7	0.872	3.5	0.742	47.0
<i>Multi-teacher distillation</i>						
AVG MTKD	0.824	32.9	0.850	4.22	0.716	45.0
CA MTKD	0.829	30.4	0.869	3.3	0.714	48.9
CA+Adapter	0.822	32.1	0.862	3.4	0.736	42.3
CA+CAGT+Annealing (Stage1)	0.829	38.4	0.869	4.3	0.736	44.4
CA+CAGT+Adapter+Stage2 (r16, $\alpha=4.0$)	0.833	39.1	0.868	5.3	0.732	46.3
CA+CAGT+Adapter+Stage2 (r64, $\alpha=2.0$)	0.829	42.7	0.865	5.3	0.741	42.9

3. 对比表目前只包含了梯度手术的对比方法，不确定是否需要添加多教师蒸馏的方法进行对比，其中的指标还有待实验完善。

Method	BUSI		ACDC		Synapse	
	Dice↑	HD95↓	Dice↑	HD95↓	Dice↑	HD95↓
<i>baselines</i>						
SAM-Med2D	0.718	23.0	0.793	2.0	0.845	4.8
MedDINOv3	0.599	97.3	0.806	2.6	0.719	39.8
Swin-Unet (task only)	0.812	44.7	0.872	3.5	0.742	47.0
<i>Gradient surgery</i>						
GradNorm	-	-	-	-	-	-
MGDA	-	-	-	-	-	-
PCGrad	-	-	-	-	-	-
CAGrad	-	-	-	-	-	-
ours	0.829	38.4	0.869	4.3	0.736	44.4

本周学习进展（2025.5.1 - 2025.5.10）

研读论文：Cross-Attention Gradient Transplantation (CAGT): Mitigating Gradient Conflict in Multi-Task Learning Through Cross-Blockwise Attention (TechRxiv-202602)，文章针对多任务学习中任务间梯度冲突导致的模型收敛缓慢、性能下降的问题，提出一套解决方案：①将共享参数对应的梯度划分为 K 个固定大小的不相交子块；②计算子块内当前任务与其他任务的平均余弦相似度，相似度小于 θ 的子块标记为冲突块；③对冲突块，通过温度缩放的余弦注意力，计算其他任务对应子块的加权组合，生成重构梯度；④将重构梯度缩放至与原始梯度一致的范数，通过插值系数 λ 与原始梯度融合。

本周已经将实验推进到三个医学数据集中，在启用数据增强的情况下，增加了多教师蒸馏后的学生模型表现完全不如单独训练，并且根据冲突情况增加 Adapter 后的指标也出现了大幅下降，目前怀疑是教师特征聚合的方式过于简单导致这种现象，下周将对这个问题开展工作。

Method	BUSI		ACDC		Synapse	
	Dice↑	HD95↓	Macro Dice↑	Macro HD95↓	Macro Dice↑	Macro HD95↓
task only	0.829	31.6	0.869	2.38	0.745	40.4
MTKD	0.824	32.9	0.850	4.22	0.716	45.0
Adapter	0.806	37.2	-	-	-	-

本周学习进展（2025.4.20 - 2025.4.30）

目前已经将研究迁移到医学图像分割，使用 Swin-Unet 作为学生模型开展了初步的实验，目前已经完成 Stage1 的实验，接下来准备编写 Stage2 的代码并进行实验。

Table 1: Segmentation performance on BUSI dataset (Swin-Unet)

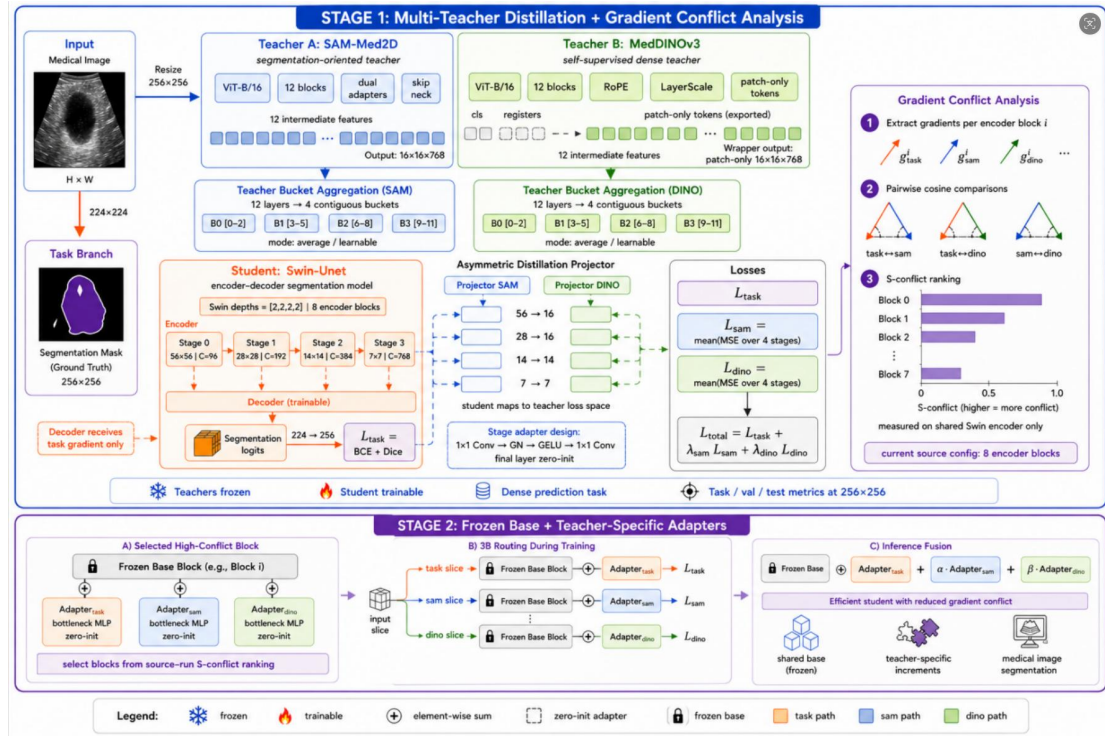
Method	Aug	Seed	Dice↑	IoU↑	HD95↓
MTKD	×	1	0.752	0.683	52.8
MTKD	×	42	0.820	0.757	34.9
MTKD	×	1998	0.832	0.764	28.4
MTKD	×	avg	0.801	0.735	38.7
MTKD	✓	1	0.742	0.672	57.5
MTKD	✓	42	0.806	0.739	38.2
MTKD	✓	1998	0.833	0.761	24.2
MTKD	✓	avg	0.794	0.724	39.9
task only	×	1	0.741	0.670	50.5
task only	×	42	0.790	0.726	40.5
task only	×	1998	0.813	0.746	32.4
task only	×	avg	0.781	0.714	41.1
task only	✓	1	0.750	0.684	52.4
task only	✓	42	0.836	0.773	27.9
task only	✓	1998	0.811	0.739	35.2
task only	✓	avg	0.799	0.732	38.5

Table 2: Teacher gradient conflict analysis.

Aug	Block (Stage:Block)							
	0	1	2	3	4	5	6	7
Seed = 1								
×	344	349	273	269	228	190	217	234
✓	620	558	404	391	366	327	361	313
Seed = 42								
×	330	323	258	248	220	175	231	228
✓	633	552	440	416	418	325	367	299
Seed = 1998								
×	377	355	291	273	257	199	212	220
✓	487	446	365	345	305	261	313	265
Average								
×	350	342	274	263	235	188	220	227
✓	580	519	403	384	363	304	347	292

Conflict: $\cos \theta < -0.02$ counting gradient direction disagreement between teachers.

以下是论文架构图：



以下是对于问题和创新点的描述：

核心问题 1：基础模型迁移中的结构异质性鸿沟

在将医学视觉基础模型（如 MedSAM-2D 与 MedDINOv3）作为教师进行知识蒸馏时，网络结构的异质性构成了首要的语义鸿沟。理想的知识蒸馏期望学生网络能无损且平滑地吸收教师的高维表征。然而，通用基础模型通常追求全局视野的平铺式特征表达，而医学图像的密集预测任务则高度依赖能够捕获多尺度局部细节的层级化架构。这种宏观上的架构错位，导致指导信号与学生网络在特征粒度、感受野及语义空间上产生严重的结构性摩擦，强行对齐往往会引发特征形变或引入上采样噪声。

具体到本研究的设定中，这一鸿沟体现为两大对齐瓶颈：学生模型采用了具有多尺度特征金字塔的层级化 Swin-Unet（特征尺度从 56×56 逐级降维至 7×7 ，通道数动态变化），而两位异构教师（SAM-Med2D 与 MedDINOv3）均采用平铺式的 Plain ViT 架构，始终输出单一的 16×16 分辨率与恒定的 768 维特征。分辨率与通道维度的双重不兼容，直接阻碍了知识的有效传递。

创新设计 1：层级桶聚合与非对称语义投影

为了跨越这一结构鸿沟，我们提出了一种自适应的特征转换范式：

语义桶聚合：打破逐层硬对齐的常规做法，将教师网络的 12 层连续特征按深度平滑聚合为 4 个语义桶。这一宏观视角的特征压缩，在保留低中高层语义梯度的同时，有效过滤了单层特征的冗余噪声，实现了与学生网络四个演化阶段的宏观对应。

非对称空间投影：我们确立了“保护教师先验空间”的非对称对齐原则：始终通过降采样将学生特征（如 56×56 ）映射至教师的低分辨率空间（ 16×16 等），而严格避免对教师特征进行破坏性的上采样插值。配合零初始化的轻量级通道投影模块（ 1×1 Conv），该设计在训练初期保持恒等映射，有效避免了维度转换过程对预训练学生底座产生的优化冲击。

核心问题 2：多监督优化动力学中的梯度倾轧

多教师蒸馏的理论基石，在于相信不同的监督信号能够产生隐式的正则化与协同增效。但在实际的优化过程中，由于异构目标所追求的优化曲面存在显著差异，它们在更新高维度的共享参数空间时极易发生冲突。这种优化方式阻碍了网络在多个优化目标间的有效权衡，导致模型表征容量被内部拉扯严重消耗，成为限制多模型协同训练性能上限的隐形天花板。

在我们的多教师医学蒸馏场景中，这一问题被具象化为层级梯度的物理冲突。SAM-Med2D（提供任务导向的结构边界）、MedDINOv3（提供通用密集纹理）以及医学分割任务本身，这三路异构目标在反向传播时，会共同作用于学生网络共享的 Swin Encoder 参数上。由于异构特征空间的显著分歧，这三个目标的优化梯度（如任务监督梯度与 DINO 蒸馏梯度）常常指向相反方向（余弦相似度为负）。这种隐蔽的梯度冲突不仅抵消了参数更新的有效性，更使得网络早期用于提取基础视觉特征的浅层网络陷入严重的表征混乱。

创新设计 2：基于物理隔离的两阶段冲突解耦

不同于传统的依赖复杂路由机制（如 MoE）或暴力梯度投影（如 PCGrad）的方法，我们使用了一种基于量化统计和结构隔离的自适应解耦框架：

第一阶段：结构化优化动力学剖析（Conflict Profiling）。我们深入学生网络内部，动态量化评估四个 Swin 阶段中任务梯度、SAM 梯度与 DINO 梯度的层级余弦相似度。通过全面监测这三对监督信号的协同状态，精准定位网络中遭受严重梯度拉扯的“高冲突瓶颈层”。

第二阶段：源头级的目标专属架构重构。针对识别出的高冲突层，我们彻底摒弃了共享更新的妥协策略。通过冻结该层的预训练 Base Block 以保全其基础表征能力，并在其旁路平行接入三个极轻量级的残差 Adapter，分别作为任务、SAM 和 DINO 目标的专属更新通道。这种物理切割（Physical Splitting），以极低的参数代价从架构源头根除了异构梯度在同构参数上的相互倾轧。

核心洞察

洞察 1: 我们的实验揭示了一个关键反常识: 异构指导引发的冲突并非在网络中均匀分布, 而是高度聚集于感受野较小的早期编码层。这是由于浅层网络在面对任务必需的医学解剖结构需求与不同教师(图像纹理 vs 边缘导向)的底层特征偏好时, 遭遇了最剧烈的语义冲突。

洞察 2: 传统观念认为数据增广必定能增强模型泛化性, 但本研究发现, 在多教师架构中, 一致的几何扰动会成倍放大不同教师模型在特征响应上的歧义, 从而大幅加剧深层网络的梯度冲突。这一发现指明, 在剖析网络基础冲突机制的早期阶段, 采用确定性预处理是隔离外源干扰、准确捕获内源动力学特征的必要边界条件。

本周学习进展 (2025. 4. 13 - 2025. 4. 19)

对已经收集到的文献进行整理, 构建思维导图。

本周学习进展 (2025. 4. 6 - 2025. 4. 12)

本周我先将手上的实验暂停了, 因为我觉得我仍然没有把问题和边界定义好, 于是我围绕多任务学习中的梯度冲突问题, 系统梳理、分析和总结了一些具备代表性的论文。

重点梳理了该方向从任务权重平衡、梯度投影、约束优化, 到结构解耦、局部梯度协调与双层优化建模的演进脉络。通过本周阅读, 我对这一问题的理解从“方法层面”进一步转向了“机制层面”。

目前我认为, 梯度冲突并不是一个孤立的优化现象, 而是多个任务在共享参数空间中竞争表示能力和更新主导权的外在表现。其本质不只是梯度方向不一致, 更在于多个任务希望同一组参数优先服务各自目标。当任务间共性较强时, 共享可以带来正迁移; 而当任务需求差异增大时, 共享参数就会成为冲突集中发生的位置, 从而导致负迁移。

从技术路线来看, 早期方法 GradNorm(2017)、Uncertainty Weighting(2018)主要试图通过调节任务权重来平衡不同任务的学习强度, 但这类方法更多处理的是单一任务影响力失衡, 未真正解决参数更新层面上的冲突。随后, 以 PCGrad(2020)为代表的方法开始直接修正梯度方向, 研究重心从任务配比转向更新几何。而 CAGrad(2021)表明, 多任务协调不能仅靠局部修补, 而需要从整体优化角度重新定义合理更新方向。

更值得注意的是, 后续工作进一步表明, 冲突并非只是优化问题, 也与参数共享结构密切相关, 与我们模型凝聚的研究方向非常相似。Recon(2023)的思路比较独特, 作者通过实验说明, 即使使用了“梯度手术”的方法, 冲突频率也没有降低, 即梯度手术虽然改变了梯度的更新方向, 但产生冲突的根源——网络的参数共享方式丝毫未变。共享层被多个任务的损失函数反复拉扯, 自然会持续不断地产生方向冲突的梯度。所以作者逐层分析梯度冲突, 计算每一层的冲突情况, 把那些冲突最严重的共享层直接改成任务专属层, 与模型凝聚侧的 SAK 有异曲同工之妙。

而 MARIGOLD(2026) 和 CAGT(2026) 等近期工作则进一步表明, 冲突其实是局部的, 不能将所有任务、所有层、所有参数一概而论。MARIGOLD(2026)将任务损失权重与模型参数更新进行解耦, 看成两个存在依赖的双层优化问题, 传统方法都忽略了这种耦合; CAGT(2026)则反对把整个梯度当整体进行处理, 而是把参数向量划分成多个块, 对应的任务梯度也就分成了多个块, 每个任务块都要进行局部冲突检测, 最后对冲突块做跨任务重组。

本周最大的收获, 是为梯度冲突方向建立起了一个的清晰框架:

1. Loss 层面的幅值平衡: 核心逻辑是由于各任务的损失函数数值尺度不同, 导致某些任务的梯度幅值天然偏大, 主导了参数更新。解决思路因此自然落在调整 loss 权重上。代表: GradNorm(2017), Uncertainty Weighting(2018)。局限性: 只管幅度, 不管方向。

2. 梯度层面的方向协调：认识到“幅值平衡不够用”之后，第二代方法将关注点转向了梯度方向本身。这一代的核心问题是：当两个任务的梯度方向不一致时，我们应该如何处理？代表：PCGrad (2020)、CAGrad (2021)。局限：全局处理，忽视内部差异。
3. 问题从优化层面向架构层面回溯：问题是梯度手术做完了，但是只改变了梯度的方向，没有改变梯度冲突发生的频率，发生冲突的根源是共享层，只要共享层存在，冲突梯度就会源源不断地产生。Recon (2023) 提出与其事后协调梯度，不如事前改变参数共享的方式。局限：先侦察，再重训，两阶段训练代价高。
4. 更加精细化的处理：延续了从梯度层面寻找更好的协调方向的思路，吸收了“局部差异”的思想。一是约束形式更精细化，二是对梯度内部结构的处理更精细化。代表：MARIGOLD (2026)、CAGT (2026)。局限：默认冲突是稳定的，假设存在一套静态的处理策略在整个训练过程中持续使用。
- 下周计划继续梳理和分析 MGDA、Dual-Balancing 等论文及其相关后续工作，建立一个完整的理论框架。

本周学习进展（2025. 3. 30 - 2025. 4. 5）

- 一、 研读论文：Generalizable Knowledge Distillation from Vision Foundation Models for Semantic Segmentation (CVPR-2026)：其中将通用表征学习与特定任务学习进行解耦的两阶段训练的思想值得注意。
- 二、 实验结果：加入表示梯度的 EMA 记忆，避免仅参考 batch-level 梯度冲突对教师权重分配决策的干扰，以下是实验结果：

Method	Food101	Cars196	DTD
baseline	79.81	52.48	42.82
PG-SEPO	78.1(-1.7)	52.46(-0.02)	42.29(-0.53)

三个实验都是负结果，从训练日志中最重要的观察，不是“新路线不稳定”，而是“新路线过于保守”。

1. 求解器几乎始终保持多教师共同参与，没有像 old pure-SEPO 那样迅速收敛到少数 teacher 主导。
2. 虽然日志显示 teacher 之间存在明显冲突，但求解器没有把这些冲突转化为真正有效的教师加权，通过统计指标看到了冲突，但没有真正利用这些冲突去做任务相关的教师权重分配，它更多是在稳定地维持一个近似均匀的解。
3. 当前结果之所以不好，不是因为它像 old pure-SEPO 那样有偏好地选择，而是因为它几乎不选择。
- 三、 未来计划跳出 UNIC 的框架来研究梯度冲突的问题，将梯度冲突优化与模型聚合这两个研究方向融合起来，搭建一个以 DINOv3-base、SAM2.1-base、SigLip2-base 为教师，vit-b 为学生的多教师蒸馏框架。

本周学习进展（2025. 3. 23 - 2025. 3. 29）

- 一、 本周为了验证 old pure-SEPO 是否能在其他数据集上稳定发挥作用，我们在 Food101、Cars196 和 DTD 三个数据集

数据集	方法	epochs	Batch / GPU	top-1 acc	Δ	训练时间	Δ
DTD	baseline	50	64	41.1	-	0:16:29	-
DTD	Pure SEPO	50	64	41.1	0	0:25:00	+51.7%
Cars196	baseline	80	64	56.6	-	1:31:42	-
Cars196	Pure SEPO	80	64	52.1	-4.5	2:33:53	+67.8%
Food101	baseline	100	48	80.1	-	13:04:54	-
Food101	Pure SEPO	100	48	84.5	+4.4	1 day 3:35:21	+110.9%

上完成了快速验证实验：

综合结果表明，old pure-SEPO 在当前这三组 quick verification 实验中并不是一个稳健、可迁移的通用方法，而是一个对数据集和训练 regime 明显敏感的方法。。

通过对实验指标进行分析，可以得到以下结论：

1. 在 Food101 上，old pure-SEPO 的 teacher 权重并不是始终均匀分配，而是在初始化附近接近均分后很快脱离平均状态。早期阶段一度表现为 DBOTFT 权重偏高；进入中后期后，权重逐步稳定转向 DINO + iBOT，其中 DINO 长期保持第一权重，iBOT 为第二权重，DBOTFT 和 DeiT3 被持续压低。与此同时，active_teacher_count 在后期基本维持在 4.0，说明它并没有塌缩成单 teacher，但这并不等于真正的均衡融合。更准确地说，old pure-SEPO 在 Food101 上学到的是一条以 DINO + iBOT 为核心的偏科路线，而不是对四个教师的充分整合。这种稳定而任务相关的 teacher 偏置，是它在 Food101 上还能保留小幅正增益的重要原因。
2. 与 Food101 不同，Cars196 上的问题并不是“始终没有学出稳定模式”，而是“学出的稳定偏置对任务无效”。从训练日志看，old pure-SEPO 在早期阶段曾短暂偏向 DBOTFT，但很快转向 DINO 强主导；进入中后期后，DINO 基本长期保持最高权重，其余教师被明显压低。也就是说，Cars196 上并不是长期混乱摇摆到最后，而是较早收敛到一条高度偏向 DINO 的单核路线。问题在于，这条路线并没有转化为更好的迁移表示，反而使最终 Top-1 相比 baseline 明显退化 -4.5。这说明“学出稳定 teacher 偏置”本身并不等于“学出有效的多教师蒸馏策略”；如果偏置方向与任务不匹配，SEPO 同样会失败。
3. DTD 上的表现又不同于前两者。它既不像 Food101 那样收敛到一个相对清晰、有效的主导组合，也不像 Cars196 那样快速锁定单一强主导教师。相反，DTD 上的权重分配更接近一种高混合、弱确定性的调度状态：DEiT3、DBOTFT 和 DINO 在训练过程中都曾阶段性占优，iBOT 则整体处于较低水平，但整体没有形成长期稳定且高置信度的主导路线。换句话说，DTD 上的问题不是剧烈崩溃，而是长期停留在一种混合但不够尖锐的 teacher 竞争区间中，最终既没有学出像 Food101 那样有效的偏置，也没有带来任何精度收益，结果与 baseline 基本持平。

综合来看，old pure-SEPO 更像一个“基于当前 batch 梯度几何进行低冲突 teacher 选择”的机制，而不是一个能够稳定发挥多教师互补性的通用融合方法。当它恰好选择到对任务更有利的主导路线时，例如 Food101 中的 DINO + iBOT 偏置，可能带来一定正收益；但当它收敛到对任务不合适的偏置，或者始终无法形成高价值的稳定组合时，就会像 Cars196 和 DTD 一样失效甚至退化

- 二、下周计划：基于对 Pure-SEPO 的实验复盘，发现目前的 SEPO 方法在跨数据集时行为不一致，仅关注瞬时的梯度冲突，缺乏对于教师权重的稳定引导。接下来打算搜集一些关于处理梯度冲突的文献，考虑引入 EMA 统计相关信息，减少瞬时的梯度冲突主导教师权重分配。

本周学习进展（2025.3.9 - 2025.3.22）

- 一、研读论文：C-RADIOv4 (Tech Report)

二、实验结果：本模型在 ImageNet-1k 上经 27 轮训练后，与训练 200 轮的 UNIC 官方预训练权重进行对比：仅在 Cars196

	ImageNet	Cars196	Aircraft	Food101	Flowers	EuroSAT	DTD	pets	Fashion-MNIST	remark
Method	top-1 acc									
UNIC	83.8	70.0	67.8	83.8	96.8	97.5	79.6	94.8	97.5	Baseline
RADIOv2.5										
SAK										
UMKD										
DUNE										
MoVE-KD										
Ours	78.8	73.8	65.8	78.6	96.7	97.4	77.7	94.3	92.0	

数据集上实现了 3.8%的性能提升，在其余数据集上仍存在一定的性能差距。

本周学习进展（2025.2.16 - 2025.3.8）

三、实验结果：经过改进，在数据集 food-101 上的实验精度有明显提升，分类准确率较 baseline 提升了 5.43%。

teacher	Student	Method	Food101	remark
			top-1 acc	
DINOv2 DeiT-III DBoT-FT iBOT	ViT	官方预训练权重	78.54	baseline
DINOv2 DeiT-III DBoT-FT iBOT	ViT	UNIC	78.67	baseline
DINOv2 DeiT-III DBoT-FT iBOT	ViT	POS+MEO	78.45	添加帕累托 优化组件
DINOv2 DeiT-III DBoT-FT iBOT	ViT	SEPO	83.1	单纯形枚举帕累 托优化器
DINOv2 DeiT-III DBoT-FT iBOT	ViT	SEPO+TFM	84.1	添加Projector融 合模块

四、继续实验：目前正在使用 ImageNet-1k 数据集进行训练，目前已训练 6 个 epoch，平均每个 epoch 耗时 15 小时。

五、项目进展：

- 就特征字段提取规则与医生达成共识。
- 制作桌面客户端的病人姓名加密解密工具。

本周学习进展（2025.2.9 - 2025.2.15）

六、实验结果：POS+MEO 几乎没有效果。

teacher	Student	Method	fashion_mnist	remark
			top-1 acc	
DINOv2 DeiT-III DBoT-FT iBOT	ViT	官方预训练权重	92.7	baseline
DINOv2 DeiT-III DBoT-FT iBOT	ViT	UNIC	93.5	baseline
DINOv2 DeiT-III DBoT-FT iBOT	ViT	SEPO	93.4	一次性优化所有教师

teacher	Student	Method	Food101	remark
			top-1 acc	
DINOv2 DeiT-III DBoT-FT iBOT	ViT	官方预训练权重	78.54	baseline
DINOv2 DeiT-III DBoT-FT iBOT	ViT	UNIC	78.67	baseline
DINOv2 DeiT-III DBoT-FT iBOT	ViT	POS+MEO	78.45	添加帕累托优化组件
DINOv2 DeiT-III DBoT-FT iBOT	ViT	SEPO		一次性优化所有教师


本周学习进展（2025.2.2 - 2025.2.6）

七、实验结果：POS+MEO 的实验还正在跑。

teacher	Student	Method	fashion_mnist	remark
			top-1 acc	
DINOv2 DeiT-III DBoT-FT iBOT	ViT	官方预训练权重	92.7	baseline
DINOv2 DeiT-III DBoT-FT iBOT	ViT	UNIC	93.5	baseline
DINOv2 DeiT-III DBoT-FT iBOT	ViT	POS+MEO		POS 控制方向 MEO 控制幅度

本周学习进展（2025. 1. 26 - 2025. 2. 1）

八、模型结构图：



九、发现的问题：梯度合并顺序导致的权重不平衡，最先被合并的教师梯度权重值衰减严重。以下是情况说明：

1. Teacher 内部 (Step 1) :

1) $\text{dino:}(\text{dino_cls} + \text{dino_patch}) \rightarrow \text{dino_fused}$

2) $\text{deit3:}(\text{deit3_cls} + \text{deit3_patch}) \rightarrow \text{deit3_fused}$

3) $\text{ibot:}(\text{ibot_cls} + \text{ibot_patch}) \rightarrow \text{ibot_fused}$

4) $\text{dbot:}(\text{dbot_cls} + \text{dbot_patch}) \rightarrow \text{dbot_fused}$

2. 跨 Teacher (Step 2, 当前链状) :

$(((\text{dino_fused} + \text{deit3_fused}) + \text{ibot_fused}) + \text{dbot_fused}) \rightarrow \text{final_grads}$

权重衰减问题：

```

            final (dino:0.14,deit3:0.21,ibot:0.35,dbot:0.3)
            /      \
    (0.7)fused_2  dbot(0.3)
        /      \
    (0.5)fused_1  ibot(0.5)
        /      \
        dino  deit3
    (0.4) (0.6)

```

3. 解决方案： 构建平衡二叉树，对梯度进行树状合并。

1) 消除顺序偏差：所有 teacher 的合并深度相同

```

4个Teachers:
Level 1: (dino + deit3), (ibot + dbot)
Level 2: (fused_left + fused_right)

示意图:
      final
     /    \
  fused_L  fused_R
   /  \   /  \
 dino deit3 ibot dbot

权重 (alpha=0.5) :
dino:  0.5 x 0.5 = 0.25
deit3: 0.5 x 0.5 = 0.25
ibot:  0.5 x 0.5 = 0.25
dbot:  0.5 x 0.5 = 0.25

```

2) 保持计算效率：复杂度仍为 $O(n)$ ，与链状相同

十、 实验结果：添加帕累托优化组件后，精度基本保持不变。

teacher	Student	Method	Food101	remark
			top-1 acc	
DINOv2 DeiT-III DBoT-FT iBOT	ViT	官方预训练权重	78.54	baseline
DINOv2 DeiT-III DBoT-FT iBOT	ViT	UNIC	78.67	baseline
DINOv2 DeiT-III DBoT-FT iBOT	ViT	POS+MEO	78.45	添加帕累托 优化组件
DINOv2 DeiT-III DBoT-FT iBOT	ViT	树状合并		使用树形合并 替换链式合并

十一、下周计划：继续搜集和研读梯度优化相关的论文和方法。

本周学习进展（2025.1.19 - 2025.1.25）

一、 搜集并研读领域最新论文：VER: Vision Expert Transformer for Robot Learning via Foundation Distillation and Dynamic Routing (ICLR-2026 审稿中)

- 总的来说，VER 走的还是 MOE 的路子，将传统 ViT 最后三层的 MLP 替换为 MoE 层，并且加上 Teacher-Specific Router 构成了专家库，训练分为两个阶段，第一阶段通过多教师蒸馏训练 encoder，第二阶段训练专家路由和政策头。
- 蒸馏训练时，为每个教师配备一个专用的 Router，每个 Router 会选择 k（超参数）个专家让它们模仿教师。用互信息损失惩罚专家坍塌的情况，鼓励所有专家都参与工作，且和自己擅长的老师绑定。
- 下游任务适配训练时，只训练 Robot Router，只占总参数的 0.4%，以及 Policy Head。专家路由的策略有：
 - FTR（帧级路由）：一帧图像只选一个老师的专家组合。
 - LTR（层级路由）：同一帧图像的不同层选不同老师的专家组合。
 - 补丁级路由（PER）：把图像分成很多 Patch，为每个 Patch 单独选最合适的专家。
- Curriculum Top-K Annealing：使用 CTA 策略减轻早期崩溃并鼓励对专家组合进行探索。
 - 训练初期：激活所有专家探索组合策略。
 - 训练中期：慢慢减少专家数量，逐步聚焦到好用的组合。
 - 训练后期：固定只选 2 个最优专家。

二、 实验结果：上周设计的投影方向反转、Transformer Projector、两阶段知识提取表现非常糟糕，分类准确率仅有 9%，学生模型完全无法学习到教师的知识。

三、 对于实验失败的反思：


- 步子跨得太大，对于 UNIC 的原模型结构和训练流程修改太多，没有深入理解和思考 UNIC 真正有作用的组件和训练方法。
- 思维不够灵活，盲目与论文实验设置进行对齐，没有使用小型数据集快速验证方法的有效性。

四、 本周实验计划：

- 保留 UNIC 的原模型结构和训练流程，从梯度优化的角度来改进模型训练，在学生对齐每个教师的损失计算完成经过 teacher dropping 后，添加 Pareto Gradient Optimization 组件，首先找到同时有利于多

个梯度下降的方向，然后对幅度进行增强。

2. 模型结构图：



3. 实验对比表：

1) 快速验证对比表：

teacher	Student	Method	Food101	remark
			top-1 acc	
DINOv2 DeiT-III DBoT-FT iBOT	ViT	官方预训练权重	78.1	baseline
DINOv2 DeiT-III DBoT-FT iBOT	ViT	UNIC	77.8	baseline
DINOv2 DeiT-III DBoT-FT iBOT	ViT	POS+MEO		添加帕累托优化组件

				ImageNet	Cars196	Aircraft	Food101	Flowers	EuroSAT	DTD	iNat2019	remark	
Teacher	Student	Method	Pub.	top-1 acc									
Foundation Model													
-	-	ViT	ICLR-2021									Baseline	
-	-	DINOv3	ArXiv-2025									Baseline	
-	-	SAM3	ICLR-2026									Baseline	
Single-Teacher Distillation													
DINOv3	ViT	FitNNets	ICLR-2015										
		ReviewKD	CVPR-2021										
		ViTKD	CVPR-2024										
		TransKD	TITS-2024										
SAM3	ViT	FitNNets	ICLR-2015										
		ReviewKD	CVPR-2021										
		ViTKD	CVPR-2024										
		TransKD	TITS-2024										
Multi-Teacher Distillation													
SAM3 + DINOv3	ViT	UNIC	ECCV-2024										
		RADIOv2.5	CVPR-2025										
		SAK	ICLR-2025										
		UMKD	MICCAI-2025										
		DUNE	CVPR-2025										
		MoVE-KD	CVPR-2025										
		Ours	-										

2) 分类任务对比表:

3) 分割任务对比表:

					VOC-2012	Cityscapes	COCO-Stuff	ADE-20k	remark
Teacher1	Teacher	Student	Method	Pub.	mIoU	mIoU	mIoU	mIoU	
Fundation Model									
-	-	-	ViT	ICLR-2021	0.669	0.586			Baseline
-	-	-	DINOv3	ArXiv-2025					Baseline
-	-	-	SAM3	ICLR-2026					Baseline
Single-Teacher Distillation									
DINOv3	SAM3	ViT	FitNNets	ICLR-2015					
			ReviewKD	CVPR-2021					
			ViTKD	CVPR-2024					
			TransKD	TITS-2024					
SAM3	DINOv3	ViT	FitNNets	ICLR-2015					
			ReviewKD	CVPR-2021					
			ViTKD	CVPR-2024					
			TransKD	TITS-2024					
Multi-Teacher Distillation									
SAM3 + DINOv3	SAM3 + DINOv3	ViT	RADIOv2.5	CVPR-2025					
			SAK	ICLR-2025					
			UMKD	MICCAI-2025					
			DUNE	CVPR-2025					
			MoVE-KD	CVPR-2025					
			Ours	-					


本周学习进展（2025.1.12 - 2025.1.18）

一、 重读论文：UDON Universal Dynamic Online distillationN for generic image representations-NIPS-2024

二、 实验：

1. 修改模型结构：UNIC 学生侧为每个教师的 CLS Token 和 Patch Token 都创建了 Projector，投影器数量很多难以管理非常臃肿。故在此基础上进行投影方向的反转，取消所有学生侧的 Projector，为每个教师配备一个 Transformer Projector（可同时处理 CLS Token 和 Patch Token），使 Teacher 特征投影到 Student 空间进行对齐，经过标准化处理后，使用两阶段的知识提取得到最终的教师共识知识。

2. 模型网络结构图：



3. 对比表:

				VOC-2012	Cityscapes	COCO-Stuff	ADE-20k	remark
Teacher1	Student	Method	Pub.	mIoU	mIoU	mIoU	mIoU	
Fundation Model								
-	-	ViT	ICLR-2021	0.669	0.586			Baseline
-	-	DINov3	ArXiv-2025					Baseline
-	-	SAM3	ICLR-2026					Baseline
-	-	DEIT3	ECCV-2022					Baseline
Single-Teacher Distillation								
DINov3	ViT	FitNNets	ICLR-2015					
		ReviewKD	CVPR-2021					
		ViTKD	CVPR-2024					
		TransKD	TITS-2024					
SAM3	ViT	FitNNets	ICLR-2015					
		ReviewKD	CVPR-2021					
		ViTKD	CVPR-2024					
		TransKD	TITS-2024					
DEIT3	ViT	FitNNets	ICLR-2015					
		ReviewKD	CVPR-2021					
		ViTKD	CVPR-2024					
		TransKD	TITS-2024					
Multi-Teacher Distillation								
SAM3 + DINov3	ViT	RADIOv2.5	CVPR-2025					
		SAK	ICLR-2025					
		UMKD	MICCAI-2025					
		DUNE	CVPR-2025					
		MoVE-KD	CVPR-2025					
		Ours	-					


				ImageNet-CoG	iNaturalist-2019	Food101	Flowers	remark
Teacher1	Student	Method	Pub.	top-1 acc	top-1 acc	top-1 acc	top-1 acc	
Fundation Model								
-	-	ViT	ICLR-2021					Baseline
-	-	DINOv3	ArXiv-2025					Baseline
-	-	SAM3	ICLR-2026					Baseline
-	-	DEIT3	ECCV-2022					Baseline
Single-Teacher Distillation								
DINOv3	ViT	FitNNets	ICLR-2015					
		ReviewKD	CVPR-2021					
		ViTKD	CVPR-2024					
		TransKD	TITS-2024					
SAM3	ViT	FitNNets	ICLR-2015					
		ReviewKD	CVPR-2021					
		ViTKD	CVPR-2024					
		TransKD	TITS-2024					
DEIT3	ViT	FitNNets	ICLR-2015					
		ReviewKD	CVPR-2021					
		ViTKD	CVPR-2024					
		TransKD	TITS-2024					
Multi-Teacher Distillation								
SAM3 + DINOv3	ViT	RADIOv2.5	CVPR-2025					
		SAK	ICLR-2025					
		UMKD	MICCAI-2025					
		DUNE	CVPR-2025					
		MoVE-KD	CVPR-2025					
		Ours	-					

本周学习进展（2025.1.5 - 2025.1.11）

本周几乎没有进行代码相关的工作，主要进行了已完成工作的总结和对未来工作的思路整理，之前的工作内容缺少重心和着力点，研究方向模糊不清，实验结果由于缺少对比对象导致没有说服力。


本周重新阅读了论文“UNIC: Universal Classification Models”，发现该论文与我现在的研究和代码框架具有一定的重合性，于是我决定以该论文为基础进行改进和创新。首先，这篇论文的目的是通过多教师蒸馏训练一个单一通用编码器，在不添加额外参数的条件下，能在多个分类任务（图像级和像素级）上都达到或超过最佳教师模型的性能，这与我的研究目标类似。其次，文章中为解决传统蒸馏中间层特征浪费的问题而提出的“阶梯式投影器”解决了令我头疼的中间层对齐的问题，并且CLS token 与 patch token 都拥有独立的投影头来进行师生对齐，比我现在只对齐 patch token 的方案更先进。最后，文章中“特征标准化”的方法也能够帮助我解决目前方案在训练时蒸馏损失与任务损失数值差异较大问题。

重构后的网络结构图：



通过对之前实验的总结以及对当前架构的分析，我决定深度挖掘下面两个问题：

- 问题一，**教师之间存在差异**：尽管两个教师模型（SAM3/DINOv3）都是基于 Transformer 架构的 VFM，但是由于目标任务和预训练范式不同，导致两个教师模型的特征存在较大差异。SAM3 经由 Promptable Segmentation 训练，其特征层级高度特化于几何结构与边缘分割；DINOv3 则基于 Masked Image Modeling，其特征层级倾向于编码全局语义与类间相关性，可视化证明如下图所示：



多教师蒸馏中不同的教师产生的特征层级不同，如果让学生强行模仿多个教师的特征，会导致学生无所适从，胡乱地更新参数，训练难以收敛。因此，筛选教师中的共识和互补知识，或者说如何设计学生的网络结构来吸收教师中的共识和互补知识，是解决该问题的关键。

2. 问题二， **任务、蒸馏梯度冲突，教师蒸馏信号对任务优化的干扰**：由于模型结构或归纳偏置的差异，不同教师对同一输入的特征关注点往往存在显著分歧，当这些特征的优化梯度方向在特征空间中相互正交甚至对立时，学生模型会收到相互矛盾的更新指令，导致特征学习陷入震荡。而教师蒸馏信号与任务监督信号的错位是更为隐蔽且致命的干扰，即便汇聚了多位教师的集体智慧，其综合指导方向仍可能与真实任务的最优梯度方向发生偏离。这意味着，源自教师的蒸馏梯度往往无法与主任务的优化目标协同，从而显著抑制了模型的训练效率与最终性能。

解决方案：

1. 目前想到一个方向：制定一个特征投票规则，先让多个教师“投票”形成共识知识，再进行蒸馏。之前我也讲过一些 SAM、DINO 的特征融合论文，走这个方向可以将特征融合的相关知识用起来。但是这样做存在两个问题，一是目前我的方案中只存在两个教师，投票是很难实现的；二是这个思路本质上是多教师蒸馏转换成单教师蒸馏（因为最终只生成一个统一的特征来与学生进行对齐），与我们的初衷相悖。
2. 对于梯度冲突，目前已经尝试过基于梯度相似性的门控开关，效果一般，并且计算量和显存占用了显著增大。接下来打算尝试帕累托优化视角下的梯度冲突解决方案：找到一个同时有利于蒸馏与任务损失优化的梯度下降方向，实现帕累托最优（无法在提升一个目标的同时不损害另一个）。

以下是对比表：

对比实验表包含四个数据集（Pascal VOC 2012、Cityscapes、COCO-Stuff、ADE-20k），主要分为三个部分：

第一部分是学生模型与教师模型独立训练的指标，作为 baseline；第二部分是单教师蒸馏的方法；第三部分是多教师蒸馏以及模型凝聚的方法。

				VOC-2012	Cityscapes	COCO-Stuff	ADE-20k	备注
Teacher1	Student	Method	Pub.	mIoU	mIoU	mIoU	mIoU	
Fundation Model								
-	-	ViT	ArXiv-2020	0.669	0.586			Baseline
-	-	Segmenter	ICCV-2021					Baseline
-	-	DINOv3	ArXiv-2025					Baseline
-	-	SAM3	ICLR-2026					Baseline
Single-Teacher Distillation								
DINOv3	ViT	FitNNets	ICLR-2015					
		ReviewKD	CVPR-2021					
		ViTKD	CVPR-2024					
		TransKD	TITS-2024					
SAM3	ViT	FitNNets	ICLR-2015					
		ReviewKD	CVPR-2021					
		ViTKD	CVPR-2024					
		TransKD	TITS-2024					
		EfficientSAM3	ArXiv-2025					
Multi-Teacher Distillation								
SAM3 + DINOv3 (vitb16)	ViT	ScaleKD	NIPS-2024	0.7147				
		RADIOv2.5	CVPR-2025					
		SAK	ICLR-2025					
		UMKD	MICCAI-2025					
		DUNE	CVPR-2025					
		MoVE-KD	CVPR-2025					
		Ours	-					
	Segmenter	ScaleKD	NIPS-2024					
		RADIOv2.5	CVPR-2025					
		SAK	ICLR-2025					
		UMKD	MICCAI-2025					
		DUNE	CVPR-2025					
		MoVE-KD	CVPR-2025					
		Ours	-					

本周学习进展（2025. 12. 29 - 2025. 1. 4）

一、 整理论文笔记：

1. RADIOv2.5 Improved Baselines for Agglomerative Vision Foundation Models(CVPR-2025)
2. Fantastic Gains and Where to Find Them On the Existence and Prospect of General Knowledge Transfer between Any Pretrained Model(ICLR-2024)
3. MoVE-KD: Knowledge Distillation for VLMs with Mixture of Visual Encoders(CVPR-2025)

二、 论文研读：

Layer-wise correlation and attention discrepancy distillation for semantic segmentation (Pattern Recognit-2026)

为解决层对齐问题搜集并阅读了该论文，文章提出了一种用于语义分割的层间相关性与注意力差异蒸馏（LCADD）框架，旨在解决现有知识蒸馏（KD）方法仅依赖单层结构化知识、忽略层间差异知识的缺陷。该框架包含两个核心组件：相关性差异蒸馏（通过构建像素级相关性差异矩阵捕捉层间空间依赖）和注意力差异自蒸馏（引导学生网络浅层模仿深层的注意力差异图实现自学习），并通过融合任务损失、传统 KD 损失及两种差异蒸馏损失形成总损失函数。在

Cityscapes、Pascal VOC 2012 和 CamVid 三大基准数据集上的实验表明，LCADD 在不同师生网络架构下均优于 SKD、CWD 等主流方法，最高可提升 mIoU 达 2.54%，同时保持轻量化和架构无关性，有效平衡了语义分割的准确性与计算效率。虽然该论文提出的方法并不能直接用于多教师蒸馏的层选择，但是其中蕴含着一种关系蒸馏的思路值得学习。

三、 实验：修改了动态权重的策略，让任务损失始终占据主导，权重始终为 1，蒸馏损失权重从 0 开始随着训练进程的推

Teacher1	Teacher2	Student	Method	VOC-2012	Cityscapes	COCO-Stuff	备注
				mIoU	mIoU	mIoU	
单独训练							
\	\	ViT	单独训练	0.674	0.586		Baseline
\	\	Mask2Former	单独训练		0.833		SOTA
\	\	EoMT	单独训练	0.819	0.812	0.421	SOTA
蒸馏训练							
SAM3	DINOv3 (vitb16)	ViTb16	固定权重 手动对齐	0.4384			训练过程不够稳定，指标经常波动
SAM3	DINOv3 (vitb16)	ViTb16	动态权重 手动对齐	0.7139			以任务损失为主导，固定任务损失权重为 1，从 0 开始逐步增加蒸馏损失权重后，指标得到明显提升
SAM3	DINOv3 (vitb16)	ViTb16	动态权重 手动对齐 梯度相似	0.7147			加入梯度相似性开关，几乎没变化

进逐渐增大，效果有显著提升，蒸馏训练结果较学生模型单独训练 mIoU 提升 3.99。

接下来计划实现 two loss, one goal 论文中的损失改进思路，希望以帕累托优化的视角，找到同时有利于两个教师损失和一个任务损失梯度下降方向。

本周学习进展（2025.12.22 - 2025.12.28）

三、 整理论文笔记：

- Theia Distilling Diverse Vision Foundation Models for Robot Learning(CoRL-2024)
- UNIC Universal Classification Models via Multi-teacher Distillation(ECCV-2024)
- UDON Universal Dynamic Online distillationN for generic image representations (NIPS-2024)

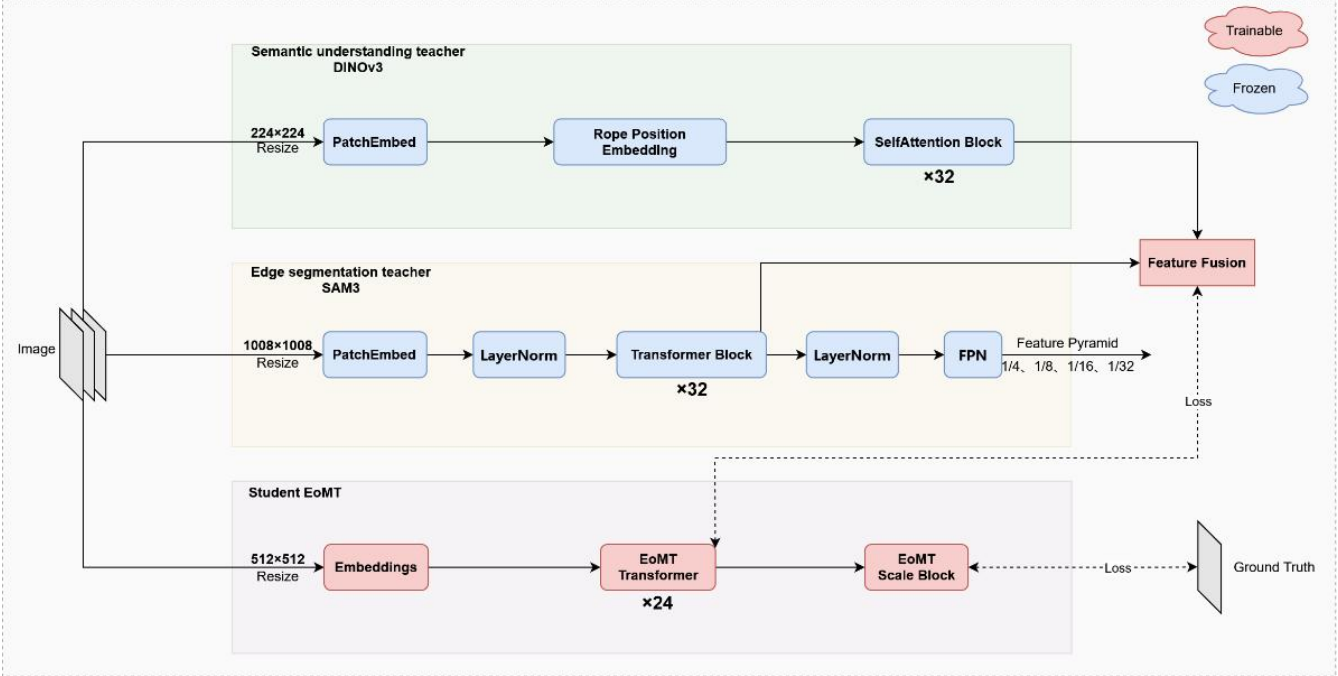
四、 论文研读：

Two Losses, One Goal: Balancing Conflict Gradients for Semi-supervised Semantic Segmentation (ICCV-2025)

五、 实验：

分别选取了 SAM3 的第(7, 15, 23, 31)层, dinov3 的第(3,6,9,12)层, ViT 的第(3,6,9,12)层进行中间层特征对齐。但是

Teacher1		Teacher2		Student		Method	VOC-2012	Cityscapes	COCO-Stuff	备注
Model	Structure	Model	Structure	Model	Structure		mIoU	mIoU	mIoU	
单独训练										
\	\	\	\	ViT	ViT-B	单独训练	67.48%	68.98%		Baseline
\	\	\	\	Mask2Former	Swin-B	单独训练		83.38%		SOTA
\	\	\	\	EoMT	DINOv2-base	单独训练	81.98%	81.28%	42.18%	SOTA
蒸馏训练										
SAM3	\	DINOv3	vitb16	ViT	vitb16	固定权重 手动对齐	43.84%			训练过程不够稳定, 指标经常波动
SAM3	\	DINOv3	vitb16	ViT	vitb16	动态权重 手动对齐	49.88%			随着训练推进稳定收敛, 但是后劲不足
SAM3	\	DINOv3	vitb16	ViT	vitb16	动态权重 手动对齐 梯度相似开关				



实际上加入多教师蒸馏训练之后的效果不佳, 指标 mIoU 在 VOC-2012 数据集上下降了将近 20%, 正在排查原因。

本周学习进展 (2025. 12. 15 - 2025. 12. 21)

一、整理论文笔记:

- Swiss Army Knife Synergizing Biases in Knowledge from Vision Foundation Models for Multi-Task Learning (ICLR-2025)
- AM-RADIO Agglomerative Vision Foundation Model Reduce All Domains Into One (CVPR-2024)
- DUNE Distilling a Universal Encoder from Heterogeneous 2D and 3D Teachers (CVPR-2025)
- DSU-Net An Improved U-Net Model Based on DINOv2 and SAM2 with Multi-scale Cross-model Feature

二、文献查找：

Two Losses, One Goal: Balancing Conflict Gradients for Semi-supervised Semantic Segmentation (ICCV-2025):
聚焦于蒸馏损失梯度方向可能矛盾的问题，从 Pareto 优化视角出发，提出 POS 动态分配梯度权重，找到同时利于两目标的下降方向。这篇文章与我们的研究方向关联度很高，预计下周进行精读。

三、实验：

Teacher1		Teacher2		Student		Method	VOC-2012	Cityscapes	COCO-Stuff	备注
Model	Structure	Model	Structure	Model	Structure		mIoU	mIoU	mIoU	
单独训练										
\	\	\	\	ViT	ViT-B	单独训练	67%	68%		Baseline
\	\	\	\	Mask2Former	Swin-B	单独训练		83.30%		SOTA
\	\	\	\	EoMT	DINOv2-base	单独训练	81.90%	81.20%	42.10%	SOTA
蒸馏训练										
SAM3	\	DINOv3	vitb16	ViT	vitb16	固定权重 手动对齐				训练过程不够稳定，指标经常波动

本周学习进展（2025.12.08 - 2025.12.14）

四、研读论文：

Masked-attention Mask Transformer for Universal Image Segmentation (CVPR-2022)：

1. 研究背景与动机：现有通用架构（如 MaskFormer、K-Net）存在性能短板、训练效率低的问题，难以替代专用架构。希望提出一款通用、高性能、易训练的图像分割架构，同时覆盖三类分割任务，且性能超越专用模型。
2. 提出方法：

a) 骨干特征提取器：采用 ResNet、Swin Transformer 等骨干网络提取低分辨率特征。

b) 像素解码器：默认使用 MSDeformAttn，将骨干特征上采样为高分辨率像素嵌入。

c) Transformer 解码器：处理对象查询，输出二进制掩码与类别标签。

d) 掩码注意力：调制注意力矩阵，仅允许查询关注预测掩码的前景区域。
3. 结果：

在数据集 COCO、ADE20K、Cityscapes、Mapillary Vistas 上的全景分割、实例分割、语义分割任务上均取得超越或取得 SOTA 结果。
4. 总结：与 EoMT 相比，Mask2Former 是更加经典、认可度更高的模型，同时测试精度也不输 EoMT，只是效率会比 EoMT 稍差，可以将 Mask2Former 也作为学生模型来验证蒸馏框架的有效性，预计先采用从编

码器的浅层、中层、高层中各选一层 block 进行特征蒸馏的方式进行快速验证。

五、实验：

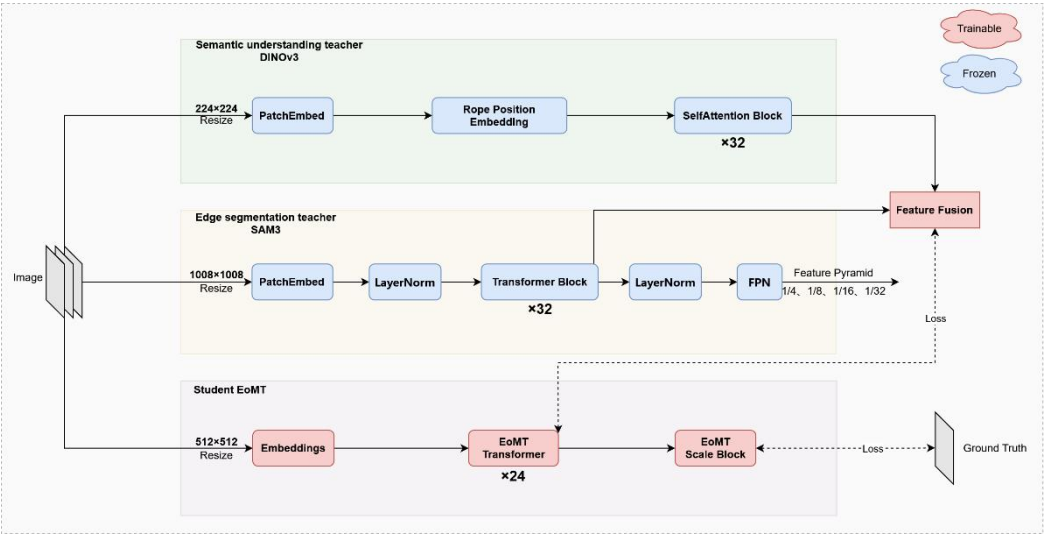
模型 EoMT 在 COCO-Stuff 上的训练完成，mIoU 为 42.1%取得较好的结果。接下来计划对 Mask2Former 进行复现。

Teacher		Student		Method	VOC-2012	Cityscapes	COCO-Stuff
Model	Structure	Model	Structure		mIoU	mIoU	mIoU
		Mask2Former	Swin-B	单独训练			
\	\	EoMT	DINOv2-base	单独训练	81.9%	81.2%	42.1%
DINOv2+SAM2	ViT-base	EoMT	DINOv2-base	浅, 中, 高 特征蒸馏			

本周学习进展（2025. 12. 01 - 2025. 12. 07）

六、实验：

- 要解决的问题：
 - 特征提取器中间层如何对齐；
 - 如何提取 DINOv3、SAM3 中的有用特征并进行特征融合；
 - 动态蒸馏还有没有更好的方法；
 - 是否有更好的损失函数；
 - Transformer Projector 与 MLP Projector 对比。



2. 网络结构图：
3. 实验结果：学生模型 EoMT 在数据集 VOC-2012 和 Cityspaces 上单独训练的结果达到 SOTA 级别。

Teacher		Student		Method	VOC-2012	Cityspaces	COCO-Stuff
Model	Structure	Model	Structure		mIoU	mIoU	mIoU
\	\	EoMT	DINOv2-base	单独训练	81.9%	81.2%	
DINOv2+SAM2	ViT-base	EoMT	DINOv2-base	Encoder 最后一层特征蒸馏			
DINOv3+SAM3	ViT-base	EoMT	DINOv2-base	Encoder 最后一层特征蒸馏			
DINOv3+SAM3	ViT-base	EoMT	DINOv2-base	梯度相似性控制蒸馏			

本周学习进展（2025. 11. 24 - 2025. 11. 30）

七、 论文研读：

1. Your ViT is Secretly an Image Segmentation Model(CVPR-2025)：
 - 1) 背景：现有 ViT 分割方案需使用 ViT-Adapter 卷积提取多尺度特征、Pixel Decoder 融合特征、Transformer Decoder 生成预测，架构复杂且计算开销大。作者希望通过实验验证在移除冗余组件后，纯 ViT 架构能否实现高效且高精度的图像分割。

2) 方法:

- a) 移除 ViT-Adapter, 通过转置卷积生成特征金字塔。
- b) 移除 Pixel Decoder, 直接输入简化特征金字塔至解码器。
- c) 移除多尺度特征处理, 仅用 ViT 输出的单尺度特征 F_{16} 进行交叉注意力计算, 将 F_{16} 上采样至 F_4 计算掩码概率。
- d) 移除 Transformer Decoder, 将 Query 向量拼接至 patch tokens, 用 Encoder Blocks 直接进行注意力计算。
- e) 移除推理阶段的掩码注意力机制, 引入掩码退火训练策略, 训练初期启用完整的掩码注意力, 随着训练进程逐步降低掩码概率至 0, 实现推理时无掩码注意力开销。

- 3) 结果: 在全景分割、语义分割、实例分割三个任务上, 准确率指标与 SOTA 模型持平或仅小幅落后, 但是推理速度比同配置 SOTA 快 2x 至 4.4x。

2. DSU-Net: An Improved U-Net Model Based on DINOv2 and SAM2 with Multi-scale Cross-model Feature Enhancement (arXiv-2025.05)

- 1) 背景: 基础模型参数量极大, 针对特定领域进行微调硬件门槛极高, 难以在实际场景中普及; 单一模型难以兼顾多尺度细节与高维语义, 导致模型特征表示不足。

2) 方法:

- a) 设计了轻量级适配器解决训练成本高的问题。
- b) 提出双编码器协作架构解决特征表示不足。

- 3) 结果: DSU-Net 模型在显著目标检测和伪装目标检测的基准测试中取得了最先进的性能, 超过或达到了 SOTA 方法。

八、思维导图整理:

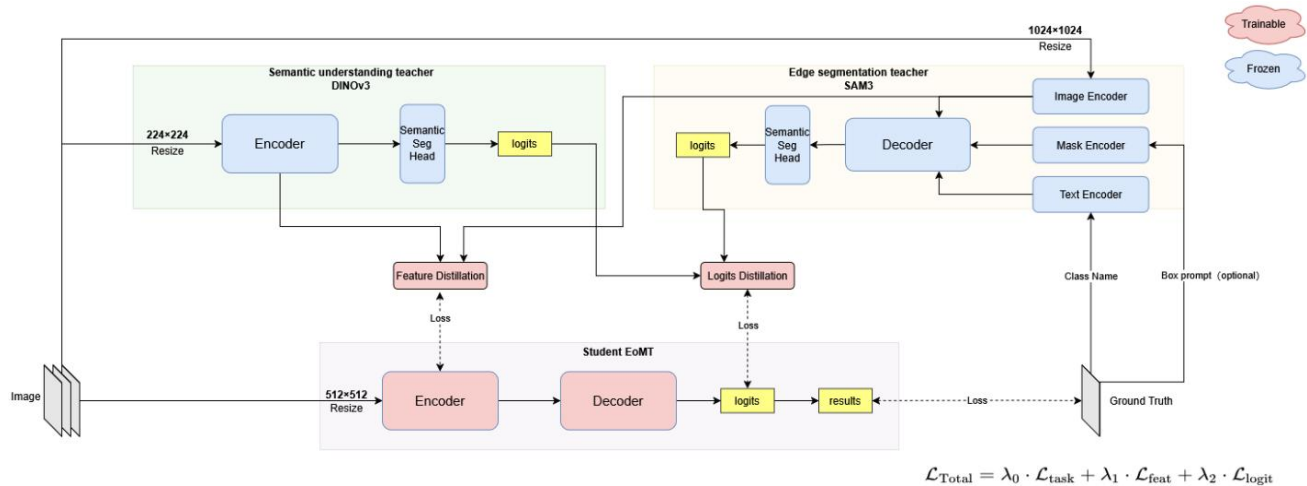
1. 特征蒸馏:

- 1) SAM-Teacher: SAM can be a Good Teacher for Enhancing Medical Image Segmentation (SMC-2025)
- 2) SAM-AEKD SAM-Based Knowledge Distillation with Adaptive Fusion and Edge Features for Enhancing Medical Image Segmentation (IJCNN-2025)

2. 多教师蒸馏:

1) Multi-teacher based knowledge distillation for retinal vessel segmentation(HISS-2025)

九、实验：



1. 构建了新的网络结构图：
2. 阅读上图三个模型的官方仓库代码并尝试运行。

本周学习进展（2025. 11. 17 - 2025. 11. 23）

一、 论文研读：

1. 《Hiera: A Hierarchical Vision Transformer without the Bells-and-Whistles》：
 - 1) 背景：ViT 架构简洁、支持 MAE 等高效预训练，但参数利用低效；Swin、MViTv2 等通过卷积、移位窗口等组件实现多尺度特征学习，提升了参数效率，但复杂组件导致推理速度慢，且与稀疏预训练（如 MAE）兼容性差；
 - 2) 方法：复杂组件的核心作用是添加空间偏置，而该偏置可通过强预训练任务（MAE）让模型自主学习，无需手动设计复杂架构。
 - a) 掩码单元局部注意力：按掩码单元遮蔽像素，并且仅在 32×32 像素的局部掩码单元内计算注意力，而非全图计算。这样既保证了局部特征的精细捕捉，又大幅减少了计算量，让模型在低资源消耗的情况下高效学习局部细节。
 - b) 阶段过渡：先对 Q 矩阵进行 2×2 最大池化操作，再将同样的操作应用在特征图上，最后经过线性层，最终实现特征通道数

翻倍、分辨率减半的效果。

c) 注意力机制：前两阶段使用掩码单元内局部注意力；后两阶段使用全局注意力。

3) 结果：图像分类任务、视频动作识别任务、COCO 检测和分割、迁移测试均优于同规模 ViT。

2. 《SAM2-UNeXT An Improved High-Resolution Baseline for Adapting Foundation Models to Downstream Segmentation Tasks》：总结见 PPT。

二、实验：

1. 对比了发表在 TPAMI-2025 上的模型 LRFormer 和 CVPR-2025 上的模型 SegMAN，决定将语义分割学生模型更换为 SegMAN。与 LRFormer 相比，SegMAN 的优点主要体现在以下 3 点：

- 1) SegMAN 模型结构更加复杂，能够有更好的容量吸收双教师的特征信号；而 LRFormer 的核心模块 LRSA（低分辨率自注意力）存在天然局限，为了速度牺牲了部分精度。
- 2) SegMAN 和 LRFormer 的解码器虽然都考虑到了多尺度特征聚合，但是 LRFormer 的解码器设计更简单，易出现语义信息稀释的情况。
- 3) SegMAN 本身已在多个主流分割数据集接近或达到 SOTA：
 - a) ADE20K: SegMAN-B (51.8M 参数) 达 52.6% mIoU，比 SegNeXtL (SOTA 级) 高 1.6% 且少 15% GFLOPs；
 - b) Cityscapes: SegMAN-B 达 83.8% mIoU，比 SegFormer-B3 (主流模型) 高 2.1% 且 GFLOPs 减半；
 - c) COCO-Stuff: SegMAN-B 比 VWFormer-B3 高 1.6% mIoU 且计算成本更低。

本周学习进展 (2025.11.10 - 2025.11.16)

一、论文研读：

1. 《MOOSEG: Rethinking Imbalanced Medical Image Segmentation》

- 1) 背景：数据偏倚（器官大小、模态异质）与算法偏倚（损失函数偏好）导致分割性能不平衡。固定损失加权（FLW）无法收敛至完整帕累托前沿，梯度冲突时需牺牲部分性能。

- 2) 方法: MOOSeg 采用多目标优化和集成学习, 构建多专家网络(共享骨干+异质损失), 通过帕累托梯度整合联合优化, 保证训练结果收敛至帕累托平稳点。
- 3) 结果: AbdomenMRI 和 WORD 数据集, nnUNet、SegResNet、U-Mamba 骨干, DSC/NSD 稳定提升(U-Mamba 在 WORD: 85.1→86.5), 16 器官分割更均衡。

2. 《IAMNET: INFORMATION-AWARE MULTI-SCALE NETWORK FOR ROBUST MARINE-ANIMAL SEGMENTATION》:

- 1) 背景: 海洋生物分割受尺度变化、低能见度及背景杂乱影响。现有 CNN、Transformer 模型难捕捉细粒度细节, SAM 在水下场景适应性有限。
- 2) 方法: 提出名为 IAMNet 的 U 型框架, 基于 SAM2 Hiera 编码器, 包含:

信息感知模块(IAM): 自适应强调有效特征、抑制冗余。

多尺度上采样块(MSUB): 通过跳连融合多尺度特征、恢复细粒度空间细节。

- 3) 结果: 使用 MAS3K、RMAS、UFO-120、RUWI 四个基准数据集验证, 在 mIoU 等五项指标上多数超越 SOTA 方法。

3. 《UDON Universal Dynamic Online distillation for generic image representations》:

- 1) 背景: 通用图像表征难以捕捉域特异性知识及适应跨域分布差异, 导致通用与专用模型间存在性能差距。

- 2) 方法: 提出 UDON(通用动态在线蒸馏)框架:

共享骨干的多教师蒸馏(每教师专精一域, 与学生在线联合训练)。


基于实时损失的动态采样, 优先分配批次给复杂域(多类别、长尾)。

- 3) 结果: 使用 UnED 基准数据集(4.1M 图像、349k 类、8 个域)实现 SOTA, 显著缩小与领域专用模型(Specialist+Oracle)的性能差距。

二、实验: 多教师蒸馏实验在 COCO-Stuff 数据集上已完成训练, 指标 mIoU 较基线模型提升 4.24%。尽管指标提升一般, 但也初步验证了多教师蒸馏方法的有效性。

	Pascal VOC-2012		COCO-Stuff	
模型	mIoU(↑)	fwIoU(↑)	mIoU(↑)	fwIoU(↑)
Segmenter (单独训练)	60.23%	82.40%	38.14%	65.15%
Segmenter (多教师蒸馏)	71.99%	88.58%	42.72%	67.06%

1. 实验结果:



2. 网络结构图:

本周学习进展 (2025. 11. 03 - 2025. 11. 09)

三、实验：本周在更大的数据集 coco-stuff 上重新进行了多教师蒸馏实验, 虽然多教师蒸馏的实验还没有跑完, 但是已经可以证明多教师蒸馏训练的效果优于独立训练。推测 Segmenter 在两个数据集上独立训练时表现不好的原因, 主要是使用的 ViT-Base 架构容量有限, 导致模型表征能力不足, 最终影响了评估指标。

	Pascal VOC-2012		COCO-Stuff	
模型	mIoU (%)	fwIOU (%)	mIoU (%)	fwIOU (%)
Segmenter (多教师蒸馏)	71.99	88.58	41.81% (训练 7 轮)	66.85 (训练 7 轮)
Segmenter (单独训练)	60.23	82.40	39.58 (训练 100 轮)	66.00 (训练 100 轮)

四、下周计划：

1. 阅读论文《Multi-target Knowledge Distillation via Student Self-reflection》(IJCV-2023)。
2. 实现 Student customized knowledge distillation 组件并加入蒸馏框架中。

本周学习进展 (2025.10.27 - 2025.11.02)

五、研读论文：

1. Switchable Online Knowledge Distillation (ECCV-2022)
 - 1) 为解决在线知识蒸馏中师生模型蒸馏差距(训练阶段师生预测分布差异)过大导致学生性能受损的问题, 本文提出可切换的在线知识蒸馏。
 - 2) 使用师生网络软化输出的 L1 范数 G 来度量蒸馏差距, 当 G 大于自适应切换阈值 δ 时启用专家模式, 当蒸馏差距 $G \leq \delta$ 时启用学习模式。
 - 3) 学习模式即师生网络均更新, 从零开始训练; 专家模式即冻结教师网络参数, 仅更新学生网络。

个人感觉这篇文章的 idea 与《Student Customized Knowledge Distillation》的思路非常相似, 都是通过度量师生差距来控制蒸馏的过程, 只不过这篇文章将学生和教师同时从零开始训练, 并且量化了训练阶段师生分布差异, 从而控制是否更新教师参数。

六、实验：以下结果可以初步证明多教师蒸馏的有效性，Segmenter 表现较差的原因有可能是数据集 PASCAL VOC-2012 较小。

模型	mIoU(%)
Segmenter (多教师蒸馏)	67.21
Segmenter (单独训练)	60.23
FCN (2015)	62.2

本周学习进展 (2025.10.20 - 2025.10.26)

七、研读论文：

1. UNIC Universal Classification Models via Multi-teacher Distillation (ECCV-2024)
 - 1) 构建 UNIC 模型，实现跨任务的强泛化能力，无需添加特定的任务参数。
 - 2) 针对现有的多教师蒸馏框架，提出并实施了以下改进：
 - a) 提出教师特征标准化，蒸馏前对教师特征做零均值、单位方差标准化，用指数移动平均实时学习统计量；
 - b) 为 CLS / patch token 设置专用投影头，为每个教师分别设计 CLS 专用投影头和补丁专用投影头；
 - c) 提出阶梯式投影器，在学生的每个中间层添加 MLP 投影头，汇总所有层投影结果至教师专用投影头；
 - d) 提出教师丢弃正则化，每轮迭代对单张图像，保留损失最大的教师，其他教师按伯努利分布（概率 p ）丢弃，确保学习均衡。
2. Student Customized Knowledge Distillation: Bridging the Gap Between Student and Teacher (ICCV-2021)
 - 1) 使用 Center Kernel Alignment (CKA) 度量师生网络表示相似性（CKA 分数越高，容量匹配度越好），发现了容量不匹配是间歇性的。同一迭代中，不同层匹配度差异大；不同迭代中，同一层匹配度波动大。

- 2) 得到结论：无需全程关闭蒸馏，只需在不匹配时暂停，匹配时保留。
- 3) 提出基于梯度余弦相似度来进行相似性的开关判断，蒸馏损失与主损失梯度方向偏离或正交，产生负迁移，此时关闭蒸馏开关。

八、可视化工具：

1. 构建了可视化工具 github 仓库，并提交了卷积可视化工具的代码。

九、实验：

1. 实现了多教师知识蒸馏框架，使用 SAM 和 DINOv2 作为教师模型，Segmenter 作为学生模型，以对齐中间特征层的方式进行蒸馏。
2. 超参数设置：batch_size=3、accumulation_steps=8 等效 batch size = 24，起始 learning rate=1e-4，总训练轮次为 150 轮，优化器为 AdamW，AdamW 的权重衰减设置为 1e-4，任务损失与蒸馏损失比例为 2:1，学习率调度器为 ReduceLROnPlateau。
3. 在语义分割数据集 PASCAL VOC-2012 上的实验结果：多教师蒸馏后的 segmenter 表现较差，仅比 FCN 的测试结果好一些，由于单独训练的代码还没写完，暂时还无法对比多教师蒸馏的效果。

模型	mIoU(%)
Segmenter(多教师蒸馏)	67.21
Segmenter（单独训练）	待测
FCN（2015）	62.2
DeepLab v3+（2018）	87.8

本周学习进展（2025.10.13 - 2025.10.19）

一、研读论文：

1. Swin-Unet: Unet-like Pure Transformer for Medical Image Segmentation
2. Student Customized Knowledge Distillation: Bridging the Gap Between Student and Teacher

二、实验：

- 1. 实现了用于计算衡量师生特征表示相似性的 CKA 分数的函数；以及实现了计算梯度相似性的函数。预计下周完成绘图代码的编写。
- 2. 本周使用数据集 BUSI 对 MedSAM 进行微调，提升明显，MedSAM 目前在该数据集上表现非常好。MedDINO v3 代码较复杂，正在调整，预计下周完成 MedDINO v3 的微调。

用途	模型	平均 Dice 系数	平均 HD95
教师 1	MedSAM(origin)	82.95	22.13
	MedSAM(fine-tuning)	95.14	27.18
教师 2	DINO V1 or V2	待测	待测
	MedDino V3	待测	待测
学生	Swin-Unet	0.8087	21.53
蒸馏	Ours-1	待定	待定

本周学习进展（2025.09.22 - 2025.10.12）

三、研读论文：

- 1. [DINO_v1] Emerging Properties in Self-Supervised Vision Transformers
- 2. EMCAD: Efficient Multi-scale Convolutional Attention Decoding for Medical Image Segmentation

四、实验：

1. 数据集 BUSI：

维度	模态	任务类型	解剖结构	解剖区域	类别数	数据量	文件格式
2D	超声	分割	乳腺	胸部	3	780	png

手动将 BUSI 数据集的 benign 和 malignant 类别按 8:1:1 划分为训练集、验证集和测试集。

2. 模型情况：

- 1) MedSAM 未微调，直接加载官方提供的预训练权重进行测试；
- 2) Swin-Unet 在 BUSI 的训练集和验证集上进行训练，在测试集上进行指标测试。

3. 测试结果：

用途	模型	平均 Dice 系数	平均 HD95
教师 1	MedSAM(直接)	0.8295	
	MedSAM(Fit-tuning)	0.94	
教师 2	Dino V1 or V2		
	MedDino V3		
学生	Swin-Unet	0.8087	21.5393
蒸馏	Ours-1		

本周学习进展（2025.09.15 - 2025.09.21）

一、继续完成相应蒸馏实验：

1. 思路梳理：吸取上周实验一的经验，进一步加强教师模型并削弱学生模型，而且使用难度更高的数据集，从而使学生自主学习难度加大，更加依赖教师模型的知识，体现知识蒸馏相较于单独训练的优越性。
2. 数据集和模型：使用 Food-101 作为本次实验的数据集，这是一个拥有 101 种不同的食物类别，共计 101,000 张图像的中型数据集。使用 EfficientNet-B3 作为教师模型，MobileNetV2 作为学生模型。
3. 超参数：训练 epoch 为 100 轮，早停耐心为 10 轮；软标签 temperature=3.0，alpha=0.6；使用 AdamW 优化器，lr=5e-4，weight_decay=0.01；使用 CosineAnnealingLR 调度器。
4. 试验结果：教师模型（EfficientNet-B3）准确率：85.49%，蒸馏训练学生模型（MobileNetV2）准确率：85.31%，单独训练学生模型（MobileNetV2）准确率：83.10%
5. 总结：在高难数据集中，较为强大的教师模型通过知识蒸馏能够提升弱小模型的准确率。

二、完成多教师蒸馏实验：

1. 数据集和模型：使用 Food-101 作为本次实验的数据集，ResNet-50、DenseNet-121、EfficientNet-B3 作为教师模型，MobileNetV2 作为学生模型。
2. 超参数：训练 epoch 为 100 轮，早停耐心为 10 轮；软标签 temperature=3.0，alpha=0.6；使用 AdamW 优化器，lr=5e-4，weight_decay=0.01；使用 CosineAnnealingLR 调度器。

3. 实验结果：经过 30 个 epoch 的微调，ResNet-50、DenseNet-121、EfficientNet-B3 分别达到 87.22%、85.67%、87.43%的准确率；MobileNetV2 经过 100 个 epoch 的独立训练达到 83.10%的准确率；经过 100 个 epoch 的多教师知识蒸馏训练达到 84.89%的准确率。
4. 总结：多教师知识蒸馏方法实现了 1.79%的性能提升。虽然提升幅度不大，但证明了多教师知识蒸馏方法的有效性。提升幅度相对较小的原因可能是因为学生模型本身已经具有较强的独立学习能力。

三、阅读论文《SAM-Teacher: SAM can be a Good Teacher for Enhancing Medical Image Segmentation》:提出自适应特征对齐模块（AFAM）动态建立师生特征层对应关系；提出边缘感知蒸馏模块（EPDM）针对性蒸馏 SAM 的边缘感知能力，解决全局对齐忽略边缘细节的问题。

本周学习进展（2025.09.08 - 2025.09.14）

一、实现蒸馏训练代码：

1. 实验一：

- 1) 数据集与损失函数设计：使用 cifar-10 作为数据集，损失函数使用 `nn.CrossEntropyLoss()` 作为硬标签损失函数，使用 `nn.KLDivLoss(reduction='batchmean')` 作为软标签损失函数。使用超参数温度参数 T 和损失权重 α 分别用于控制概率分布的软化程度和软标签损失、硬标签损失在损失中的占比。
- 2) 模型：使用 ImageNet 预训练的 ResNext101_64x4d 作为教师模型，ResNet-18 作为学生模型。
- 3) 微调教师模型：替换 ResNeXt101_64x4d 的分类头，解冻高层 layer4 参数，对教师进行微调训练。经过 50 轮训练后达到 82.36% 的准确率。
- 4) 知识蒸馏训练：学生模型（ResNet-18）经过教师模型（ResNeXt101_64x4d）50 轮的训练后，达到 83.98% 的准确率。
- 5) 对比试验：学生模型（ResNet-18）单独训练 50 轮后，达到 85.75% 的准确率。蒸馏训练的最终准确率相比学生模型单独从头训练略有下降（-1.77%）
- 6) 思考：可能是 CIFAR-10 数据集较小导致难度不够，学生模型自

已学习已经能够学得比较好了，无法体现蒸馏学习的优势。

2. 实验二：

- 1) 思路梳理：吸取实验一的经验，进一步加强教师模型并削弱学生模型，而且使用难度更高的数据集，从而使学生自主学习难度加大，更加依赖教师模型的知识，体现知识蒸馏相较于单独训练的优越性。
- 2) 数据集和模型：使用 Food-101 作为本次实验的数据集，这是一个拥有 101 种不同的食物类别，共计 101,000 张图像的中型数据集。使用 EfficientNet-B3 作为教师模型，MobileNetV2 ($\alpha=0.5$) 作为学生模型。
- 3) 试验结果：正在跑。
- 4) 总结：待总结。

二、阅读综述《分割一切模型 SAM 的潜力与展望综述》(中国图像图形学报-2024)，读了一半。

本周学习进展 (2025.08.25 - 2025.08.31)

一、研读 SAM 论文 (Segment Anything)：

1. 背景及目的：在 NLP 领域，以 GPT 为代表的基础模型实现了通过预训练和提示工程的方式使得单个模型能够适配多种任务，作者期望在 CV 领域中也构建出这样的视觉基础模型。即通过“可提示的通用分割能力”，构建图像领域的基础模型，期望实现零样本迁移到各类下游任务。
2. 相关工作：
 - 1) 提出可提示分割任务 (Promptable Segmentation Task)，使训练出来的模型极强的通用性和泛化能力。
 - 2) 使用重量级图像编码器 (Image Encoder) 和轻量级提示编码器 (Prompt Encoder)、掩码解码器 (Mask Decoder) 这种不对称的结构设计，实现了一次图像编码，多次轻量交互的操作，提高了与用户交互时的实时性。
 - 3) SAM 的掩码解码器会为每个提示生成多个候选掩码，使同一个提示能够生成多个合理分割结果，实现歧义感知的效果。

4) 公开了 SA-1B 数据集以及数据集的构建方法。

3. 实验:

1) SAM 在 23 个数据集中的 16 个 mIoU 高于 RITM, 证明 SAM 能从指定的提示中生成高质量掩码。

2) 选取 4 类下游任务证明 SAM 能够实现零样本迁移, 具备极强的泛化能力。

二、学习微调方法 LoRA:

1. 原理: 全参数微调会产生一个更新矩阵 ΔW , 对于特定任务, 这个完整的更新矩阵 ΔW 是低秩的。即 ΔW 虽然尺寸很大 ($d \times k$), 但其有效信息可以由一个远小于 $\min(d, k)$ 的秩 r 矩阵来捕捉。

2. 核心思想: 将更新矩阵 ΔW 分解为两个连续的低秩矩阵的乘积, 仅对这两个低秩矩阵进行训练更新。数学表达式: $\text{output} = Wx + \Delta Wx = Wx + Bax$ 。

3. 实现细节: 暂时未使用代码实现, to-do。(存在疑惑: 如何微调 SAM? 是随便找点数据集使用 LoRA 的方式训练模型并替换输出头吗?)

三、研读 MedSAM 论文 (Segment Anything in Medical Images):

1. 背景与目的: 医学影像与自然图像存在本质差异, 期望构建一个医学影像领域的通用基础模型。

2. 我的疑惑: 阅读该论文的初衷是学习 MedSAM 是如何在 SAM 的基础是进行微调的, 但是看了作者的相关工作之后还是不明白具体应该如何进行微调。

3. To-do: 作者开源了代码库, 需要查看具体代码进行学习。

本周学习进展 (2025.08.11 - 2025.08.17)

一、卷积神经网络:

1. 系统学习并理解了 SENet、DenseNet、ResNet 等经典 CNN 的核心原理与结构。成功使用 PyTorch 实现了这些模型, 并在实验室服务器上使用 FashionMNIST 数据集完成了训练与验证。

2. 调研了 SENet 之后 CNN 的发展脉络, 重点关注了 EfficientNet (2019)、GhostNet (2020)、ConvNeXt (2022)、UniRepLKNet (2023)、SCConv (2023)、

OverLoCK(2025)。目前正深入学习 EfficientNet 的缩放策略和复合系数方法。

3. 卷积神经网络模型可视化方法探索：

- 1) 结构可视化:使用 torchinfo 打印模型结构图。
- 2) 特征图可视化:通过 forward-hook 捕获中间层特征张量, 利用 matplotlib 绘制特征图。
- 3) 特征激活热力图:实现并应用了 Grad-CAM 方法生成特征激活图。
- 4) 神经元激活可视化:单个神经元响应模式的可视化方法仍在探索中。

二、Transformer:

1. 系统学习并理解了 Transformer 的核心思想、整体架构及工作流程, 深入掌握了多头注意力机制的原理与计算过程。
2. 系统学习并理解了 ViT 的原理、架构与实现细节。使用 pytorch 搭建了一个 ViT-Base 模型
(patch_size=16, embed_dim=384, layers=12, heads=6), 在 MiNi-ImageNet 数据集上训练 100 轮。结果显示: 训练准确率达 80%, 但验证集准确率在第 40 轮达到峰值 45%后下降, 测试集准确率为 43%, 存在严重过拟合现象。下一步计划先简化模型, 减少层数或者降低嵌入维度。

三、轻量级卷积神经网络:

1. 系统学习并理解了 MobileNet 系列的核心思想, 深入掌握了其关键组件深度可分离卷积的原理与计算步骤: 先进行逐通道的空间卷积, 再通过 1x1 卷积进行通道信息融合, 这样大大减少了计算量。
2. 系统学习并理解了 ShuffleNet 的核心思想: 通过对通道分组进行卷积以降低计算量, 并利用 Channel Shuffle 操作打乱通道顺序, 促进不同通道组间的信息交流。

一、 本周学习进展 (2025. 07. 21 - 2025. 07. 27)

一、DenseNet 卷积神经网络

- 1) 学习了 DenseNet 中 Dense Layer、Dense Block、Transition Layer 的原理: Dense Layer 由最基础的卷积层构成。学习了 BN 的原理和核心作用: 稳定每层输入分布从而加速收敛、将数据归一化至梯度敏感区缓解梯度问题。

- 2) 掌握了 DenseNet 网络整体架构，基于 PyTorch 搭建了 DenseNet-201，各个 Dense Block 的层数配置为 [6, 12, 48, 32]。
- 3) 代码复现
 - i. 使用 CIFAR-10 作为数据集来训练 DenseNet-201，将训练集按 8:2 比例划分为训练子集和验证子集，应用了随机裁剪和水平翻转进行数据增强，batch_size=256（2080ti 单卡训练）。
 - ii. 计划训练 300 轮，使用 SGD 优化器，设置初始学习率为 0.1，动量为 0.9，权重衰减为 1e-4；在第 150 和 225 个 epoch 分别将学习率乘以 0.1；使用混合精度训练（AMP）。
 - iii. 训练时间为 1h 38m，最佳验证集准确率为 75.68%，测试准确率为 75.12%。

二、 本周项目进展（2025.07.14 - 2025.07.20）

1. 尝试将京东登录二维码输出在后台管理页面的实时日志上，但是输出后的二

码无法正常显示。



```
[2025-07-27 22:26:25] INFO: 查询到 30860 个未抓取评论的
[2025-07-27 22:26:25] INFO: 启动浏览器实例, 端口: 127.0
[2025-07-27 22:26:39] INFO: 未检测到登录状态, 正在打开登
[2025-07-27 22:26:40] INFO:
[2025-07-27 22:26:46] INFO: 用户已登录
[2025-07-27 22:26:47] INFO: 打开商品页面
[2025-07-27 22:26:56] INFO: 页面加载完成
[2025-07-27 22:26:56] INFO: 开始监听数据包
```

三、 下周计划（2025.07.28 - 2025.08.03）

1. 学习并复现 SENet，制作 DenseNet 讲解 PPT。
2. 在云服务器上调试项目，解决二维码图片无法在实时日志中显示的问题。
3. 对 DenseNet 进行调优，解决验证准确率与测试准确率太低的问题。

一、 本周学习进展（2025.07.14 - 2025.07.20）

1. ResNet 卷积神经网络

- 4) 学习了 ResNet 中残差块的原理：短路保留原始信息，避免模型退化。
学习了 BN 的原理和核心作用：稳定每层输入分布从而加速收敛、将数据归一化至梯度敏感区缓解梯度问题。
- 5) 掌握了 ResNet 网络整体架构，基于 PyTorch 搭建了 ResNet-34，包含 16 个残差块。
- 6) 使用 FashionMNIST 作为数据集来训练 ResNet-34，batch_size=256*4（4 卡并行训练时每张显卡显存占用为 10GB 左右），模型在 43 轮训练后达到最佳验证准确率 94.57%，在测试集上的准确率为 94.17%。

二、 本周项目进展（2025.07.14 - 2025.07.20）

- 1. 继续完善后台管理页面：评论抓取功能现在可以选择商品类别了、爬虫任务的实时日志可以显示在页面上了。
- 2. 了解微信公众号的分类和注册流程：
 - 订阅号：以传达资讯的功能为主。服务号：以服务交互功能为主。
 - 注册主体：主要分为个人和企业，个人注册需要身份信息、企业注册需要营业执照。

公众号	服务号
为媒体和个人提供一种新的信息传播方式，构建与读者之间更好的沟通与管理模式。	给企业和组织提供更强大的业务服务与用户管理能力，帮助企业快速实现全新的公众号服务平台。
适用于个人和组织	不适用于个人
群发消息1条/天	群发消息4条/月
消息显示位置公众号列表	消息显示位置服务号列表
基础消息接口/自定义菜单有	基础消息接口/自定义菜单有
高级接口能力无	高级接口能力有
微信支付无	微信支付可申请

三、 下周计划（2025.07.21 - 2025.07.27）

- 1. 学习并复现 DenseNet，制作 DenseNet 讲解 PPT。
 - 2. 在云服务器上调试项目，尝试将登录二维码展示到实时日志中以成功启动爬虫任务。
-

一、 本周学习进展（2025.07.7 - 2025.07.13）

1. VGGNet 卷积神经网络

- 1) 使用 Kaiming 权重初始化的方法解决了 VGGNet-16 模型在训练过程中不收敛的问题。
- 2) 使用 FashionMNIST 作为数据集来训练 VGGNet-16, batch_size=544 (4 卡并行每张显卡显存占用为 10GB 左右), 优化器为 Adam (lr=0.001), 模型经过 50 轮训练后在验证集上的最佳准确率为 93.53%, 在测试集上的准确率为 93.61%。

2. GoogLeNet 卷积神经网络

- 1) 学习了 GoogLeNet 中 Inception 模块的构成, 以及通道合并(concat)、 1×1 卷积、全局平均池化 (GAP) 等关键创新点。
- 2) 掌握了网络整体架构, 并基于 PyTorch 搭建了含 9 个 Inception 模块的 GoogLeNet。
- 3) 使用 FashionMNIST 作为数据集来训练 VGGNet-16, batch_size=256*4, 模型经过 50 轮训练后在验证集上的最佳准确率为 94.92%, 在测试集上的准确率为 94.41%。

二、 本周项目进展（2025.07.7 - 2025.07.13）

1. 完善了前端的数据展示页面 demo 和后台管理页面 demo。
2. 增加了爬虫状态查询的相关接口

三、 下周计划（2025.07.14 - 2025.07.20）

1. 学习 ResNet, 使用 pytorch 搭建、训练该模型。
2. 完成项目前端页面相关功能的开发。