



FCN语义分割 算法原理



- 输入特征图的一个像素
- $s-1: 32-1=31$ 该模块为31个0元素
- $k-p-1: 64-16-1=47$ ，该模块为四周填充47宽度的0元素




主流视觉任务

语义分割是计算机视觉中一种图像分析任务，其目标是为图像中的每一个像素赋予一个类别标签，语义分割提供更精细、像素级别的理解。


常见的图像识别任务包括图像分类、目标检测、语义分割和实例分割。




(a) Image classification



(b) Object localization



(c) Semantic segmentation



(d) This work

图像分类：识别整张图像的主要类别，**不关注位置或数量**。

目标检测：识别图像中所有目标**位置和类别**。

语义分割：对每个**像素分类**，标出属于**哪个类别**。像素级别的类别掩码，不区分实例。

实例分割：在语义分割基础上，进一步区分同类目标的不同实例。每个实例的**像素掩码 + 类别信息**。

语义分割的应用场景

1、自动驾驶：识别道路、行人、车道线、交通标志等，实现环境感知。

2、医学图像分析：分割器官、肿瘤、病灶区域，辅助诊断与手术规划。

3、遥感图像处理：土地利用分类，如分割建筑物、农田、水体等。

语义分割任务的发展历史

传统语义分割模型

1. 基于阈值;
2. 基于图像分层和纹理的方法;
3. 基于聚类的方法;
4. 基于边缘的方法。

基于深度学习语义分割算法模型

FCN (2014.11) : 第一个将传统分类的 CNN 改造成像素级预测的架构, **开创了基于深度学习的语义分割新时代。**

U-Net (2015.5) : 原本是为**医学图像分割**设计的, 它在参数量不大的前提下, 能跑出非常不错的结果。医学图像、卫星图像、农业图像等对分割精度要求高、小数据量的领域广泛应用 U-Net。

DeepLab (v1、v2、v3) (2016-2018) : v1 引入空洞卷积 + CRF, v2 加入 ASPP 多尺度特征, v3 去除 CRF 强化 ASPP, v3+ 加入 Encoder-Decoder 提升边缘精度。

高级阶段 (2019-至今) : Attention、Transformer, 多任务融合、自监督方法融入到语义分割中。例如:


- 1、HRNet (多尺度融合提升精度)
- 2、DANet (通道注意力 + 空间注意力)
- 3、SegFormer与SETR (都利用了Transformer)
- 4、还有一些其他的模型 (Mask2Former, SAM、OneFormer) 。

其他典型算法: 由于这块的研究较多还有一些比较知名的算法模型。例如: SegNet、PSPNet。

利用卷积算法模型进行分类

卷积模型进行分类的模型结构：

- 1、输入一个**固定大小**的图片
- 2、经过卷积层和池化层的特征提取，最终输出的特征图有一个特性，就是特征图的**高宽下采样一定倍数，通道数变大**。
- 3、将特征图通过一定的方法进行展平和**全连接层对接**。
- 4、最后一层全连接层的神经元个数应是**类别的数量**
- 5、利用softmax函数映射最后一层神经元的输出，输出值为概率值。所有值相加等于1。




FCN模型如何进行语义分割


利用FCN模型进行语义分割任务，本质上也是一个分类任务，只不过从任务本质来说对**图像进行像素级的分类**（也就是**每个像素点**都进行分类）。

FCN模型有如下特性：


- 1、模型的输入图片可以是**任意大小**（yolo系列的目标检测模型的输入也是任意大小的。）
- 2、模型的特征提取网络可以是任意任意**卷积网络模型**（最初FCN网络的特征提取网络为VGG，pytorch官方代码中用的是ResNet网络。）
- 3、最后网络模型的输出为和输入图像一样**高宽的高维向量**。



FCN模型输出解析



转置卷积（反卷积）



转置卷积（Transposed Convolution）在语义分割或者对抗神经网络（GAN）中比较常见，其主要作用就是做上采样。


对于转置卷积需要注意的是：

- 1、转置卷积不是卷积的逆运算。
- 2、转置卷积也是卷积运算的一种。
- 3、转置卷积也可以被称为反卷积。

同时在深度学习中上采样的方法也有很多，

- 1、最近邻插值（在yolo目标检测算法中利用过）
- 2、双线性插值（在FCN网络中也利用该方法进行上采样）

上采样的目的就是将卷积提取的特征缩放到原图大小，这样就可以对像素进行像素级别的分类了。



普通卷积计算方式

1	2	3	4
5	9	6	7
9	0	3	2
1	2	3	4

*

1	2
3	4

=

56	

1	2	3	4
5	9	6	7
9	0	3	2
1	2	3	4

*

1	2
3	4

=

56	57

1	2	3	4
5	9	6	7
9	0	3	2
1	2	3	4

*

1	2
3	4

=

56	57
20	

1	2	3	4
5	9	6	7
9	0	3	2
1	2	3	4

*

1	2
3	4

=

56	57
20	32

0	0	0	0	0
0	0	1	2	0
0	3	4	5	0
0	6	7	8	0
0	0	0	0	0

*

0	1
2	3

=

0	3	8	4
9	19	25	10
21	37	43	16
6	7	8	0

计算公式：

$$OH = \frac{H + 2P - FH}{S} + 1 \leftarrow$$

$$OW = \frac{W + 2P - FW}{S} + 1 \leftarrow$$

转置卷积计算方式

转置卷积的计算过程及其公式:

1、特征图元素间填充: 在输入特征图元素间填充s-1行和列。

2、特征图四周填充: 在输入特征图四周填充k-p-1行和列。




3、将卷积上下、左右翻转。

4、和普通卷积一样做卷积运算 (这个时候按普通卷积的过程来计算, 填充是0, 步幅为1)。

卷积计算输入和输出特征图大小计算公式:

$$OH = (H-1) \cdot S - 2P + FH$$

$$OW = (W-1) \cdot S - 2P + FW$$



转置卷积计算方式

转置卷积的计算过程及其公式:

1、特征图元素间填充:
在输入特征图元素间填充s-1行和列。


2、特征图四周填充: 在
输入特征图四周填充k-p-1行和列。

3、将卷积上下、左右翻转。

4、和普通卷积一样做卷积运算。

$$OH = (H - 1) \cdot S - 2P + FH$$

$$OW = (W - 1) \cdot S - 2P + FW$$




```
self.upscore = nn.ConvTranspose2d(  
    in_channels=21,  
    out_channels=21,  
    kernel_size=64,  
    stride=32,  
    padding=16,  
    bias=False  
)
```

注意:


该套参数并不是唯一参数, 只要满足输出尺寸公式, 你就可以用多种不同的S,P,K组合来从 7×7 上采样到 224×224。

FCN模型语义分割结构


论文的版本中，FCN进行语义分割是利用VGG作为主干网络来作为主干提取特征的，但是随着深度学习的不断发展，后续有更多特征提取能力更强的网络被发明，因此很多代码中利用的主干提取网络并不是VGG。Pytorch官方提供的FCN网络主干利用的是ResNet。



全卷积网络为何可以接受任意大小的输入呢？




在全卷积网络中，如果模型中含有全连接层，那么输入的大小就是限定的。因为卷积接入全连接的时候需要展平操作，此时全连接层参数是依据输入数据和神经元决定的。当模型训练完毕后，输入别的大小的数据会导致参数匹配不上，模型不能进行前向传播进行推理。



在全卷积网络中，经过多次卷积和池化后，原始的输入图片会下采样（缩小）一定倍数，如果想要对图像进行语义分割，则只需要将提取的特征图上采样（扩大）对应的倍数即可。因此全卷积网络可以对输入图片不做要求，理论上任意大小的图片都可以作为输入。

FCN模型几个版本



	FCN-AlexNet	FCN-VGG16	FCN-GoogLeNet ⁴
mean IU	39.8	56.0	42.5
forward time	50 ms	210 ms	59 ms
conv. layers	8	16	22
parameters	57M	134M	6M
rf size	355	404	907
max stride	32	32	32

	pixel acc.	mean acc.	mean IU	f.w. IU
FCN-32s-fixed	83.0	59.7	45.4	72.0
FCN-32s	89.1	73.3	59.4	81.4
FCN-16s	90.0	75.7	62.4	83.0
FCN-8s	90.3	75.9	62.7	83.2

FCN网络的损失函数

在标准的FCN中，它的损失函数其实就很朴素的，**像素级的分类交叉熵（Pixel-wise Softmax + Cross-Entropy Loss）**。具体的解释如下所示：

- 1、对于输入图像的每一个像素点；
- 2、FCN会输出一个**类别概率向量**（比如你有21个类别，就输出21维，每一维是对应某个类别的概率）。
- 3、对每一个像素，计算它的预测类别分布和真实标签（one-hot的）之间的**交叉熵**。
- 4、最后对所有像素的交叉熵取平均（或者求和），得到总损失。

总结一句话：

FCN的损失函数=对每个像素做softmax分类交叉熵，再全图平均。

像素级的分类交叉熵公式：


$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log p_{i,c}$$

N = 总像素数；

C = 类别数；


$y_{i,c}$ 第 i 个像素的真实标签（属于类别 c 就是1，不属于就是0）；

$p_{i,c}$ 第 i 个像素被预测为类别 c 的概率。




膨胀卷积(空洞卷积)

膨胀卷积也被称为空洞卷积，是一种改进卷积操作的技术，旨在增加卷积核的感受野，而不增加计算量。其核心思想是通过插入空洞来扩展卷积核的有效感受野，使其能够捕获更大范围的上下文信息。



K=3, S=1, P=0



K=3, S=1, P=0, D=2

$$OH = \frac{H + 2P - FH}{S} + 1$$

$$OW = \frac{W + 2P - FW}{S} + 1$$

$$OH = \frac{H + 2P - D \times (F_H - 1) - 1}{S} + 1$$

$$OW = \frac{W + 2P - D \times (F_W - 1) - 1}{S} + 1$$

注意当参数为膨胀率 (Dilation rate) 为1的时候，此时膨胀卷积等同于普通卷积

代码对应的FCN模型模型结构

