

分割一切模型的轻量化研究综述

罗一畅^{①②③④} 齐析屿^{①②③④} 张博锐^⑤ 师汉儒^{①②③④} 赵妍^{①②③④}
王磊^{①②③} 刘世雄^{*①②}

^①(中国科学院空天信息创新研究院 北京 100094)

^②(目标认知与应用技术重点实验室 北京 100094)

^③(中国科学院大学 北京 100190)

^④(中国科学院大学电子电气与通信工程学院 北京 100190)

^⑤(新加坡国立大学 新加坡 119077)

摘要: Meta公司提出的分割一切模型(SAM)作为计算机视觉领域的基础模型,在图像分割、目标检测与跟踪等任务中展现出强大的零样本泛化能力。然而, SAM模型依赖计算密集型的图像编码器(如ViT-H)和复杂的任务解码架构,导致高昂的计算资源消耗和存储需求,严重限制了其在边缘设备、移动终端等资源受限场景中的实际部署。为提升SAM的实用性,近年来研究者提出了多种轻量化方法。该文系统性综述了相关进展:首先,从任务范式、模型架构、数据引擎和应用领域等多方面简要介绍了SAM的基本情况。其次,回顾了高效基础架构替换、知识蒸馏、模型量化和模型剪枝等模型压缩方法。在此基础上,进一步概述了重构模型结构和轻量化网络替代等方法在当前SAM轻量化研究中的具体应用情况。最后,聚焦效率和精度上的平衡问题,对SAM轻量化模型未来的发展方向进行了深入分析和讨论。

关键词: 分割一切模型; 轻量化网络; 图像分割; 模型压缩; 知识蒸馏

中图分类号: TN911.7; TP391.41

文献标识码: A

文章编号: 1009-5896(2026)02-0713-19

DOI: 10.11999/JEIT250894

CSTR: 32379.14.JEIT250894

1 引言

近年来,基础模型的出现为人工智能领域带来了一场引人注目的技术革命^[1]。这类在海量数据上预训练的大规模神经网络,具备强大的表征能力和下游任务泛化性能。在自然语言处理(Natural Language Processing, NLP)领域,基于Transformer架构^[2]的大语言模型(Large Language Models, LLMs)^[3-6]迅速发展,成为当前最主流的研究趋势。2020年,视觉Transformer (Vision Transformer, ViT)^[7]的提出标志着Transformer架构成功从自然语言处理(NLP)拓展到计算机视觉(CV)领域。CLIP^[8]通过跨模态对比学习,首次实现了自然语言监督下的视觉表征学习; BEiT^[9], MAE^[10]

等方法借鉴BERT^[11]思想,采用掩码图像建模方法进行自监督学习; DINO^[12]等框架则展示了无监督条件下ViT的特征提取能力。这些工作共同构成了视觉基础模型的核心技术脉络。在视觉基础模型快速发展的背景下,2023年4月Meta AI提出的分割一切模型(Segment Anything Model, SAM)^[13]将这一范式成功拓展到图像分割领域,其“Promptable Segmentation”(可提示分割)的任务范式,使单一模型能够通过点、框或文本等多样化提示完成任意图像分割任务,为后续的视觉基础模型提供了设计思路。

尽管原始的Segment Anything 模型在通用图像分割任务中展现出强大的性能,但其计算效率问题也逐渐成为制约实际应用的瓶颈。特别是基于ViT-Huge架构的SAM-H模型,由于其参数量庞大(约637 M)、计算复杂度高,严重限制了其在嵌入式系统、移动终端等实际场景的部署可行性。这种性能与效率之间的矛盾,促使后来的研究开始探索在尽可能保持模型泛化能力的同时,显著提升其计算效率的改进方案。

目前已有一些综述从不同的角度提供了概述。Zhang等人^[14]首次全面介绍了SAM基础模型的研究进展;文献^[15]的综述则专注于介绍SAM在医学图像分割中的有效性和潜在研究方向;王淼等人^[16]则

收稿日期: 2025-09-09; 改回日期: 2025-11-03; 网络出版: 2025-11-11

*通信作者: 刘世雄 liusx@aircas.ac.cn

基金项目: 目标认知与应用技术重点实验室(2023-CXPT-LC-005), 空天院科学与颠覆性技术项目(AIRCAS2024-AIRCAS-SDTP-03), 中国科学院重点部署项目(RCJJ-145-24-13, KGFZD-145-25-38)

Foundation Items: The Laboratory of Target Cognition and Application Technology (2023-CXPT-LC-005), The Science and Disruptive Technology Program (AIRCAS2024-AIRCAS-SDTP-03), The Key Program of Chinese Academy of Sciences (RCJJ-145-24-13, KGFZD-145-25-38)

重点关注于SAM的改进方法及其应用进展。然而现有的这些综述大多聚焦于SAM的发展历程、技术原理及其下游任务的创新应用,对于如何实现SAM轻量化这一关键方向的探讨仍较为零散。为了进一步填补这一领域的空白,本文重点关注SAM轻量化方法,根据其轻量化策略对其进行分类总结,并详细介绍SAM轻量化的发展现状和应用进展。最后,讨论了目前SAM轻量化方法有待完善的问题,并提出了未来几个潜在的研究方向,期望有助于高效视觉基础模型的发展。本文框架如图1所示。

2 关于SAM

随着人工智能向通用人工智能 (AGI) 演进,基础模型成为发展的关键,自然语言处理领域的大语言模型已取得显著进展,并展现出卓越的零样本和少样本迁移能力。受此启发,2023年Meta AI提出SA(Segment Anything)^[13]项目,针对计算机视觉领域分割任务缺乏通用模型的问题,设计了由图

像编码器、提示编码器和轻量级掩码解码器所组成的图像分割基础模型SAM。SA项目延续了大语言模型的核心思想,试图通过超大规模数据训练,使模型获得对任意图像进行分割的泛化能力,从而突破传统分割模型需要针对特定任务进行专门训练的局限。如图2所示,SA项目由3个相互关联的组件组成:可提示的分割任务、分割一切模型 (SAM) 以及SA-1B数据引擎。

2.1 应用领域

受提示工程^[17]启发, SAM提出用一组前景(背景)点、粗略框、掩码或者自由形式的文本来作为提示输入,并返回一个有效的分割掩码。在1100万张图像中的超过10亿个高质量掩码的训练下, SAM的零样本迁移能力突出,能够适应边缘检测、目标检测和实例分割等多种下游任务场景。

SAM的主要下游应用之一是医学图像分割。在特定的CT图像^[18]、病理图像^[19]、2D医学图像^[20]等数据集上,一些工作尝试通过微调SAM模型来适应特定的医学数据集; MedSAM^[21]则使用包含




图1 本文行文框架




图2 SA项目^[13]

11种模式的综合医学图像数据集来微调SAM, 另一些工作则专注于通过自动化生成提示^[22]、优化提示策略^[23]或融入半监督网络^[24]来提高SAM对这些特定任务的适应性。

鉴于SAM具有卓越的泛化能力, 一些研究人员将其应用于目标检测任务中。其中SAM+MM-Detection框架^[25]将SAM应用到了目标检测领域, 在民用基础设施缺陷检测^[26]、农业病虫害检测^[27]、遥感目标检测^[28]等各类现实场景中, SAM都表现出了良好的泛化性。此外, SAM也被应用于图像编辑任务中, 如图像修复领域的Inpaint Anything^[29]、图像编辑领域的Edit Everything^[30]和Caption Anything^[31]。

除了图像分割任务, SAM还广泛应用于各种视频任务。受SAM启发, TAM(Track Anything Model)^[32]将SAM和XMem(一种先进的VOS模型)^[33]相结合, 利用SAM初始化目标对象掩码, 解决XMem精确掩码初始化困难的问题。在2D任务之外, 研究人员还探索了SAM在3D领域的进一步拓展应用。Liu等人^[34]将SAM用于分割不同的汽车3D点云序列, Cen等人^[35]利用SAM生成的2D掩码进行反渲染并投影到三维掩码上, 从而实现三维重建。

2.2 可提示的分割任务

图像分割作为计算机视觉的基础任务^[36], 其核心在于将图像中的每个像素赋予语义标签, 通过像素级的分类, 将图像解构成具有特定语义的区域或对象实例, 从而实现对视觉场景的深度理解^[37]。然而, 传统图像分割模型通常针对特定任务设计, 在通用性和泛化性方面存在局限。不同于传统固定任务的定义, SAM通过引入类似NLP提示工程的交互机制, 可以通过点、框或文本等多样化提示动态生成分割结果, 既能适应语义、实例等传统分割需求, 又能实现开放域下的零样本迁移。

2.3 分割一切模型

SAM主要由图像编码器、提示编码器和掩码解码器3个组件构成。首先, 图像编码器以预处理后的图像为输入, 为每个图像输出一个图像嵌入, 并映射至特征空间。其次, 提示编码器主要用于将用户输入的提示映射到特征空间, 从而得到特定的嵌入提示信息。最后, 图像嵌入和提示嵌入被共同输入到轻量级的掩码解码器中, 通过将这两个信息嵌入进行整合解码后最终输出有效的掩码。

2.3.1 图像编码器

一般来说, 图像编码器可以是任何输出大小的图像嵌入网络。为了增强模型的可扩展性, SAM

使用MAE^[10]预训练的ViT-H/16变体作为骨架, 具备 14×14 窗口注意力和4个等间隔的全局注意力块, 以处理高分辨率输入。在针对输入图像的处理过程中, 图像编码器遵循标准做法^[38], 将输入调整为 1024×1024 分辨率, 较短边通过填充达到此尺寸, 然后通过图像编码器生成 64×64 尺寸的图像嵌入。

2.3.2 提示编码器

提示编码器在模型中负责处理不同类型的提示信息, 将其转化为模型能够理解和操作的向量表示。提示类型主要可以分为稀疏提示编码、密集提示编码和文本提示3种。其中, 稀疏提示(点与框)通过位置和类型嵌入区分前景与背景或框的边界; 密集提示(掩码)经卷积降采样后编码空间结构信息; 文本提示则借鉴CLIP^[8]的设计实现跨模态语义对齐。

2.3.3 掩码编码器

掩码解码器的设计旨在高效地将图像嵌入、提示嵌入以及输出Token映射到最终的分割掩码。为了确保解码器能利用关键的几何信息, 其中的每层解码器依次执行提示自注意力、提示到图像的交叉注意力、前馈网络更新和图像到提示的交叉注意力, 实现提示与图像特征的双向交互。经过多层解码后, 更新的图像特征经上采样并与输出Token结合, 最后生成高精度分割掩码。

2.4 SA-1B数据引擎

在构建图像分割基础模型时, 因缺乏网络规模的分割数据源, 为收集11亿掩码数据集SA-1B, 研究团队开发了SA-1B数据引擎, 为训练通用的视觉基础模型提供了数据基座。其构建过程经历辅助手动、半自动和全自动3个阶段: 先由标注人员利用基于SAM的交互工具进行初始标注, 再通过检测器自动生成高置信度掩码并迭代优化, 最终利用点阵提示、IoU预测与NMS筛选生成稳定掩码, 并结合多尺度裁剪提升小目标质量, 从1100万张图像中高效构建出大规模掩码数据集SA-1B。

使用包含11亿个高质量掩码的SA-1B数据集训练SAM, SAM模型能够学习到广泛的图像特征和分割模式, 这极大增强了其对新数据分布的泛化能力, 使其在单一点提示分割、实例分割、目标检测等下游任务中展现出优异的零样本迁移能力; 同时也推动了视觉基础模型在图像分割及其相关领域的进一步发展。

2.5 SAM的局限性

SAM模型虽然在图像分割领域取得了显著的进展, 但是仍然存在多方面的局限性, 主要体现在分割精度和实时性能上。

在处理复杂场景和精细结构时, SAM模型存在不足。特别是当场景中存在大量细节或相似对象时, 模型难以准确识别和分割各个物体^[39]。在医学图像分割领域, 由于医疗数据集的不同模态和不同任务之间的差距较大, 并且具有噪声大、边界模糊等特点, 给SAM的分割造成了困难^[40], 一些工作尝试从基于医学数据集的SAM微调^[41,42]以及重新设计提示^[22,43-45]出发, 从而来最大限度地发挥SAM的分割效果。

在遥感图像分割领域, 由于遥感图像(如卫星、航拍图像)与自然图像在尺度、视角、纹理等方面存在显著差异且遥感图像中的目标尺度变化较大, SAM在遥感场景的零样本泛化能力受限。近来, 一些工作分别从领域自适应^[46,47]、多尺度优化^[48]以及重新设计提示编码器^[49]这几个不同的角度出发, 来提升SAM模型在遥感领域的泛化性。

尽管SAM模型的提示编码器和掩码解码器在浏览器端能够实现快速处理(约50 ms), 但整体性能仍受限于参数量巨大(约630 M)的图像编码器, 特别是在处理高分辨率图像时, 其计算成本较高, 导致模型整体难以达到真正意义上的实时性能, 无法满足如实时视频监控、自动驾驶实时感知等实时性要求极高的应用场景。为了解决上述问题, 后续改进工作主要从重构SAM编码器^[50-53]和模型蒸馏^[54-57]两大方向出发, 来减少模型的参数, 从而降低SAM的时间和资源消耗。

过去已有综述^[43,58-60]探讨了如何提高SAM在不同任务和场景的泛化性能, 本综述重点关注总结SAM的轻量化研究进展以及提升SAM效率的改进方法。

3 轻量化方法介绍

随着SAM模型在众多下游任务中取得显著进展, 研究人员开始考虑如何进一步对SAM模型进行优化来更好地适应不同场景的下游任务, 其中, 减少SAM推理时间和资源消耗, 加快SAM的推理速度成为改进SAM的一个重要研究方向。其中, 主要方法分为两大类: 第1类方法主要采用更加高效的基础架构以替代原有SAM图像编码器, 以求减少庞大的参数量; 第2类方法则是对SAM模型进行压缩, 以减少参数量, 实现模型的轻量化, 进而加快模型推理速度。

3.1 高效的基础架构

SAM模型效率低下的主要原因是其图像编码器的庞大参数量, 如表1所示, 在SAM-H模型中, 以ViT-H为骨干网络的图像编码器包含约6.32亿个参数, 而模型总参数量约为6.41亿个, 这意味着图

像编码器占据了模型总参数的95%以上, 即便是使用更小参数量的ViT-B作为骨干网络, 图像编码器仍占据模型大部分参数。因此, 一种简单而有效的加速SAM方法就是采用更加高效的基础架构以替代原有SAM图像编码器的ViT架构, 以求减少庞大的参数量。这些高效的骨干网络通常可以分为两种方法: (1)使用更高效的视觉Transformer架构; (2)加入卷积神经网络(Convolutional Neural Networks, CNN), 设计成混合架构。

3.1.1 高效ViT架构

视觉Transformer (ViT)的基本模块包含多头自注意力(Multi-headed Self-Attention, MSA)模块^[61,62]和MLP模块, 相比于卷积神经网络(CNN), 其在捕捉长距离上下文信息、全局建模和表示方面更具优势^[63,64]。

MetaFormer^[61]从宏观架构设计的角度出发, 最初提出MSA模块并非影响Transformer性能的关键组件, 并引入不需要额外可学习参数的PoolFormer。受益于PoolFormer极简的参数, Lite-SAM^[65]将其作为构建轻量级图像编码器的基础架构。后续的MobileViTv2^[66]通过将全局信息赋予上下文向量, 简化了复杂的矩阵乘法。CAS-ViT^[67]则更进一步, 摒弃传统ViT中复杂的矩阵乘法和Softmax操作, 通过空间和通道注意力机制, 采用简单的卷积和Sigmoid激活函数实现了信息交互。

在硬件层面, Flash-attention^[68]通过利用底层硬件的内存层次结构, 将输入分块并在每个块上执行注意力操作, 从而实现了2~4倍的时钟时间加速, 并在SAM加速工作中被加以应用^[69-71]。

3.1.2 混合架构

对视觉Transformer的另一种改进思路是将CNN与Transformer结合, 构建混合模型, 从而弥补自注意力机制在处理局部信息时的不足^[72]。Mobilevit^[73]开创性地提出了MobileViT块, 将CNN块(MobileNetV2块)与Transformer块集成到了单个模型中, 分别利用标准卷积和Transformer来对局部信息和全局信息进行处理, 以学习更好的特征表示, 并在移动视觉任务中取得了较好的效果。在此基础上, MobileViTv2^[74]引入可分离自注意力方法, 进一步降低了模型的运算成本; MobileViTv3^[75]则将MobileViT融合块中的 3×3 卷积层替换为

表1 不同骨干网络的SAM模型参数量(M)

参数量	SAM-H	SAM-L	SAM-B
图像编码器	632	307	86
提示编码器与掩码解码器	9	4	4

1×1卷积层,同时,将局部和全局表示块的特征进行融合,从而进一步降低参数和提高模型性能。

Efficientvit^[76]从重构自注意力机制的角度出发,用ReLU线性注意力机制替代Softmax实现全局感受野,使得其高效骨干网络在多尺度学习能力和局部特征提取方面进一步优化,并应用在加速SAM中^[77]。

EfficientFormerV2^[78]通过从简化网络结构和降低高分辨率下注意力机制复杂度来减少模型参数,并为后续图像分割加速任务提供了启发^[79]。TinyViT^[80]创新性地引入了模型蒸馏的方法,提出的快速预训练蒸馏框架主要采用渐进式模型收缩方法,为后续SAM模型加速策略的进一步优化提供了思路^[81,82]。

3.2 视觉模型轻量化

视觉模型轻量化是指通过各种技术来减少视觉Transformer模型的参数数量和计算复杂度,以适应资源受限的环境^[83]。视觉大模型轻量化和加速的4种主要方法是知识蒸馏、模型量化、低秩适应和模型剪枝。

3.2.1 知识蒸馏

知识蒸馏 (Knowledge Distillation, KD)^[84]是一种在人工智能和深度学习领域用于模型优化的重要技术,旨在将大型复杂模型(教师模型)的知识转移到小型高效模型(学生模型),以提升学生模型的性能,同时降低计算成本和资源需求。

在视觉基础模型领域,当知识蒸馏应用于SAM轻量化的工作时,其主要目标是从具有更大参数的、具有更强特征表示的原始SAM中提取知识,并将其作为教师模型,将需要的知识和特征表示蒸馏到参数量更小的学生模型^[85]。

MobileSAM^[50]率先将知识蒸馏引入SAM压缩领域。如图3所示,与传统的耦合蒸馏和半耦合蒸馏不同,其采用了解耦蒸馏策略,聚焦于图像编码器的优化,避免了掩码解码器蒸馏可能会对图像编码器所造成的影响。在此基础上, TinySAM^[52]采用全程知识蒸馏策略,在特征提取层、中间层等网络的多个层次进行; KDSAM^[86]进一步展示了解耦

蒸馏在医学图像分割领域的有效性。还有一些研究^[87-90]通过知识蒸馏展现了SAM实现跨模态、跨数据集知识迁移的能力。

EdgeSAM^[56]引入了动态循环提示策略,同时对提示编码器和掩码解码器进行蒸馏,并将原始的基于ViT的SAM图像编码器提取为纯基于CNN的架构,以更好地适合边缘设备。KnowSAM在此基础上,在学生模型中加入两个子网络以增强内在泛化能力。

3.2.2 模型量化

模型量化作为推动神经网络高效推理的一项关键技术^[91],其主要原理是以较低的推理精度损失将连续取值(如Float32, Float16)的浮点型权重近似为有限多个离散值(如Int8)的过程。通过以更少的位数表示浮点数据,模型量化可以减少模型尺寸,进而减少在推理时的内存消耗。

在实际设计过程中,由于量化感知训练 (Quantization Aware Training, QAT)是在模型训练完成后对其参数进行量化,只需要少量的校准数据,其简单和高效的特点使得SAM轻量化模型在资源受限的环境中,能够更好地保留模型的精度^[92,93]。

3.2.3 低秩适应

低秩适应(Low-Rank Adaptation, LoRA)^[94]是一种通过低秩分解来微调大模型的技术,旨在减少微调过程中的参数量和计算开销。其核心是在微调期间将更新矩阵约束为低秩,其本质是通过矩阵分解来实现的:将原来大的权重矩阵分解成多个小的矩阵,用低秩矩阵近似原有权重矩阵,从而大大降低模型分解之后的计算量,常被用于神经网络模型的分解和压缩^[95]。

通过集成LoRA, SAM模型在语义分割方面取得了显著进展, ConvLoRA^[96]增强了SAM在遥感、医学和农业图像中的语义分割能力,在此基础上, SAMed^[97]仅对SAM的提示编码器和掩码解码器进行微调,展示了基于LoRA的微调在多器官分割任务中的有效性, SurgicalSAM^[98]将类似的技术应用于机器人手术器械分割领域。上述对于LoRA技术




图3 MobileSAM解耦蒸馏示意图^[50]

的应用主要集中在冻结SAM的大规模参数图像编码器后再进行的微调,并未直接加速或压缩SAM模型。将LoRA技术直接应用于压缩和加速SAM仍是未来的一个潜在研究方向。

3.2.4 模型剪枝

模型剪枝(Pruning)又叫模型稀疏化,不同于模型量化对每一个权重参数进行压缩,稀疏化方法是尝试直接“删除”部分权重参数^[99]。模型剪枝通过识别并移除对模型性能影响较小的部分,同时通过微调(Fine Tuning)恢复精度,使得模型减少参数数量和计算量,并生成一个更小、更高效的模型,从而适用于低功耗或低延迟场景^[100]。

在SlimSAM^[101]模型中,结构化剪枝策略首次被引入。通过估计参数重要性来识别SAM冗余,交替修剪和蒸馏不同的子结构实现模型参数数量的减少,并通过保持或调整维度保留了SAM的分割性能。

4 SAM 轻量化研究

随着SAM在各类下游任务的广泛应用,很多研究都针对资源有限场景开发了轻量化的SAM模型。这些研究都旨在降低原SAM模型的高计算成本,而尽可能地实现SAM的性能,同时保留SAM强大的分割能力和下游泛化性能。表2总结了各类针对

SAM轻量化的研究工作。

4.1 重构SAM模型结构

如3.1节所述,SAM模型效率低下的主要原因是其图像编码器的庞大参数,一种直接的方法就是借助知识蒸馏等技术,用更加高效的骨干网络来替换编码器,以减少模型的参数量。此外,在保持SAM模型分割性能的同时,重构SAM的编码器-解码器架构也是一种思路。

Zhao等人^[102]首次运用模型重构的思路,对Segment Anything模型重构为检测分支(Detect Branch)和掩码分支(Mask Branch),并提出了新的模型FastSAM。如图4所示,FastSAM将任务解耦成两个连续的阶段,包括全实例分割和提示引导。第1阶段使用CNN架构的YOLOv8-seg^[103]和YOLACT^[104]方法来对图像所有物体进行检测和分割,类似于全景分割,并生成掩码;第2阶段则是依赖于提供的提示(点、框、文本提示)将感兴趣的特定对象从全景分割中进行剥离,从而降低计算量。

作为首个实时基于CNN的Segment Anything任务解决方案,FastSAM相较于原始的SAM模型有显著的速度提升,在边缘检测和高分辨率影像建筑物提取数据集上表现较好,存在较好的零样本泛化性能^[13,105]。然而作为早期的SAM高效变体模

表 2 SAM轻量化研究工作总结

模型	发表时间(arxiv)	轻量化方法	网络结构	参数量(M)	应用领域
FastSAM ^[102]	2023.06	重构SAM	YOLOv8-Seg(CNN)	68.00	轻量化通用分割模型
MobileSAM ^[50]	2023.06	知识蒸馏	TinyViT	9.66	轻量化通用分割模型
EdgeSAM ^[56]	2023.07	知识蒸馏	CNN	9.60	轻量化通用分割模型
nnSAM	2023.09	知识蒸馏	nnUNet(CNN)	-	医学图像分割
EfficientSAM	2023.12	重构SAM	ViT-Tiny/ViT-Small	25.00	轻量化通用分割模型
RepViT-SAM ^[55]	2023.12	知识蒸馏	RepViT(CNN)	48.90	轻量化通用分割模型
SlimSAM ^[101]	2023.12	模型剪枝	SAM	9.10	轻量化通用分割模型
SqueezeSAM	2023.12	重构SAM	UNet(CNN)	19.00	交互式图像编辑工具
MobileSAMv2	2023.12	知识蒸馏	EfficientViT/TinyViT	-	轻量化通用分割模型
TinySAM ^[52]	2023.12	知识蒸馏、模型量化	TinyViT	-	轻量化通用分割模型
QMedSAM	2024.01	量化感知训练	ViT-Tiny	9.80	医学图像分割
EfficientViT-SAM	2024.02	知识蒸馏	EfficientViT	61.30	轻量化通用分割模型
FastSAM3D ^[69]	2024.03	知识蒸馏	ViT-Tiny	-	3D医学影像分割
SAM-Lightening ^[70]	2024.03	知识蒸馏	Flash Attention(ViT)	-	轻量化通用分割模型
PTQ4SAM ^[93]	2024.05	训练后量化	SAM	-	嵌入式设备分割
Lite-SAM ^[65]	2024.07	重构SAM	LiteViT(Hybrid)	4.20	轻量化通用分割模型
ESP-MedSAM	2024.07	知识蒸馏	TinyViT	28.46	医学图像分割
ESAM ^[51]	2024.08	重构SAM	U-Net+ViT	-	机器人操作、实时4D导航
KnowSAM	2024.12	知识蒸馏	UNet+SAM	-	医学图像分割
KDSAM ^[86]	2025.01	知识蒸馏	ResNet-50(CNN)	26.40	医学图像分割

注:“-”表示原始论文中无相应的数据。

型, FastSAM在分割精度尤其是分割掩模上相较于SAM有一定差距。此外, SAM原有的文本提示模块未整合进整体骨干网络中, FastSAM在文本提示引导上也存在一定性能欠缺。

与FastSAM不同, Xiong等人^[106]提出来的EfficientSAM模型使用的是预训练好的轻量级ViT图像编码器, 即SAMI (SAM-leveraged masked Image pertraining), 利用SAM的掩模图像进行预训练, 并在SA-1B上微调模型。如图5所示, EfficientSAM模型的构建过程主要分为两个阶段。第1阶段是SAMI在ImageNet^[107]上进行预训练, 借助MAE^[10]强大特征重建学习能力, 将来自SAM图像编码器的特征嵌入作为重构目标。经过SAMI预训练后, 舍弃原有解码器, 将轻量级编码器作为EfficientSAM的图像编码器。第2阶段则是在SA-1B上进行模型的微调。这种方法借鉴了掩码图像建模(Masked

Image Modeling, MIM)^[108,109]的思路, 更好地继承了SAM强大的分割能力。在目标检测、实例分割和语义分割任务中, SAMI预训练的骨干网络性能优于其他基线方法; 在零样本实例分割方面相比于其他轻量级的SAM模型在参数量和推理速度上都具备一定优势。

与EfficientSAM同时期提出的还有SqueezeSAM^[110]。其主要采用UNet^[111]架构的编码器结构并保留原始SAM中的Mask MLP模块。模型以输入图像及交互提示作为输入信号, 通过编码器提取多层次特征并由掩码MLP辅助生成分割结果。在下游任务中, SqueezeSAM可利用显著对象检测(Salient Object Detection, SOD)选择初始点, 而无须用户输入, 相较于其他模型更加适合于移动设备的照片编辑应用。

考虑到计算成本的限制, Xu等人^[112]提出的RAP-




图4 FastSAM架构示意图^[102]




图5 SAMI方法和EfficientSAM架构示意图^[106]

SAM模型采用更加简单的编码器-解码器架构,如图6所示。根据实际应用的需要,采用ResNet18^[113]等轻量级骨干网络轻量级特征提取器;统一动态卷积解码器采用基于池化的动态卷积框架,来提升解码器效率;在解码器之后,添加两个不对称设计的轻量级解耦适配器以增强视觉提示和分割掩码之间的交互,更好地平衡不同任务需求。

不同于上述的研究工作, Lite-SAM^[65]采用了一种名为LiteViT的轻量级CNN-Transformer混合架构,在保留了SAM编码器-解码器结构的同时,还加入了AutoPPN网络,如图7所示。AutoPPN网络则使用端到端的训练方式,它能同时回归边界框提示和点提示,与以往的密集位置编码方案相比,大大提高了效率。作为一种端到端的轻量级算法, Lite-SAM有效解决了SAM系列中SegEvery任务范式下计算复杂度高的问题,在推理时间上实现了16倍的加速,但牺牲了部分精度。

4.2 基于知识蒸馏的方法

考虑到SAM的编码器-解码器架构,针对SAM的知识蒸馏通常可以分为两种方法:(1)蒸馏整个SAM模型;(2)保留原始SAM的提示编码器和掩码解码器,仅蒸馏图像编码器。

4.2.1 蒸馏整个SAM模型

为了更好地适应边缘设备, EdgeSAM^[56]将原始的基于ViT的SAM图像编码器提取为纯基于CNN的架构。由于与任务无关的编码器蒸馏无法捕获SAM中包含的全部知识, EdgeSAM对提示编码器和掩码解码器同时进行蒸馏,并引入动态循环提示策略。如图8, EdgeSAM由编码器蒸馏、提示循环蒸馏和嵌入粒度首选项的轻量级模块组成,保留了

SAM的编码器-解码器架构,从而能够更好地继承SAM中框和点提示的零样本交互式分割的性能。

KnowSAM^[114]则在蒸馏整个SAM模型的策略上进行了一定的改进,引入了两个子网络作为学生模型来进行知识蒸馏,从而增强子网络的内在泛化能力,使得子网络学习到对医学图像分割任务更有价值的信息^[115,116]。

4.2.2 仅蒸馏SAM图像编码器

针对SAM压缩和加速的方法大多数都基于知识蒸馏,而相比于从头开始训练模型或者蒸馏整个SAM模型,仅蒸馏SAM图像编码器部分成为平衡性能和效率的最佳选择。通过判别蒸馏后的图像编码器骨干网络种类,可以将这些方法分为3类:(1)具有轻量级ViT网络的模型;(2)具有纯CNN架构编码器的模型;(3)针对图像编码器注意力机制进行改进的模型。

(1)轻量级ViT网络:受MobileSAM的启发,后来的ESAM^[51]使用EfficientFormerV2^[78]作为骨干网络,并采用整体知识蒸馏策略(Holistic Knowledge Distillation, HKD)将知识从专家模型转移到ESAM,以提升模型在资源受限医疗设备的性能。相比之下, nnSAM^[117]聚焦于小样本医学场景,其融合了SAM强大的特征提取能力与nnUNet^[118]的自动配置能力,以提升小数据集上医学图像分割的准确性和鲁棒性。

与上述两种方法不同, ESP-MedSAM^[119]面向多模态医学影像场景,提出了多模态解耦知识蒸馏策略(Multi-Modal Decoupled Knowledge Distillation, MMDKD),首先通过整合SAM的自然图像编码器和医学图像编码器构建了多模态教师模型,利




图6 RAP-SAM架构示意图^[112]





图7 Lite-SAM架构示意图^[65]

图8 EdgeSAM架构示意图^[56]

用其在医学源域上的微调,使两个编码器分别提供通用和特定模态知识,从而为每个医学成像模态提供独立蒸馏通道,避免模态间知识干扰。

Zhang等人^[120]在MobileSAM基础上,提出了MobileSAMv2,并采用了新的提示采样策略。针对“分割一切 (SegEvery)”范式,这种目标感知提示采样策略可以直接生成有效掩码,减少了掩码生成和过滤的时间,使得SegEvery任务变得更快。相较于之前MobileSAM所聚焦的“分割任意物体 (Segment Anything, SegAny)”任务,MobileSAMv2则聚焦于“分割一切 (Segment Everything, SegEvery)”任务,二者从不同角度对SAM进行优化,为构建高效的SegAny和SegEvery统一框架迈出重要一步。

Yu等人^[121]借鉴上述模型的经验,采用ViT-Tiny替代SAM原有图像编码器,同时保留轻量级的提示编码器和掩码解码器,并采用模型量化技术^[122]大幅减少了模型的内存占用和计算复杂度,加速推理过程。

(2)纯CNN网络: NanoSAM^[54]是基于MobileSAM的轻量级版本,其使用纯卷积神经网络ResNet18取代了基于ViT的图像编码器,并针对NVIDIA的硬件进行了深度调整。在Jetson Orin Nano上的实际测试表明, NanoSAM在实现推理速度比MobileSAM快5倍的同时,仍能保持较高的推理精度。

RepViT-SAM^[55]则采用RepViT^[123]模型替换SAM中的图像编码器。由于RepViT结合了ViT和CNN的优点,使其在零样本边缘检测和零样本实例分割等多数指标上优于MobileSAM和ViT-B-SAM,且推理速度快10倍。

(3)改进注意力机制: 在2D图像任务上, Zhang

等人^[124]提出的EfficientViT-SAM模型使用EfficientViT^[76]来初始化图像编码器,并在SA-1B数据集上进行端到端训练,在不牺牲性能的同时显著提升了效率。其中EfficientViT通过改进注意力机制,将传统Softmax注意力的二次复杂度替换为基于ReLU的线性注意力,从而使得模型在处理图像时,能更高效地获取全局感受野,避免了因计算量过大导致的效率低下问题。Song等人^[70]提出的SAM-Lightening进一步采用扩张式快速注意力机制(Dilated flash attention),在稀疏化预处理的同时用快速注意力机制进行并行计算,从而提高处理速度。

相比之下,在3D场景中,Shen等人^[69]开发的FastSAM3D模型针对体积医学图像的高维特征引入了3D稀疏注意力机制。其通过在编码器和解码器阶段对输入序列进行空间分区稀疏化,最后再融合为全局表示,从而在保证空间一致性的同时有效减少了冗余计算。与2D任务相比, FastSAM3D创新性地 将稀疏注意力机制拓展至3D空间,但其高维场景下的模型复杂度和实现成本也面临挑战。

4.3 基于模型量化的方法

如图9, TinySAM^[52]与传统的知识蒸馏只关注输出层不同,其所采用的全程知识蒸馏策略 (Full-stage knowledge distillation) 在特征提取层、中间层等网络的多个层次上进行。为了进一步降低计算成本,控制精度损失, TinySAM模型把PTQ(训练后量化)应用到基于提示的分割任务中,并结合硬掩码加权和硬提示采样策略显著降低了模型参数量与推理延迟,同时仍能维持接近原始SAM的分割性能。

考虑到模型直接进行量化可能造成的信息丢失, PTQ4SAM^[93]量化框架提出自适应粒度量化策

略,用于解决SAM直接量化可能带来的量化误差和性能损失,从而提高模型的量化性能^[125]。

不同于上述研究所用的训练后量化方法,Lu等人^[126]针对医学图像分割推理时计算资源需求大的问题,首次将量化感知训练(Quantization-Aware Training, QAT)引入SAM模型压缩领域,提出了QMedSAM模型。QMedSAM选择仅对图像编码器和掩码解码器中的矩阵乘法进行量化,采用直通估计器(Straight-Through Estimation, STE)^[127]解决量化不可微问题,以更好地适应数据特性,提升量化效果。

4.4 基于模型剪枝的方法

当前SAM压缩的大部分方法是采用轻量级架构替换原图像编码器并从头开始训练网络,这会导致在训练数据有限的情况下性能不理想,传统剪枝虽然能够减少数据的需求但是也会导致性能下降。

Chen等人^[101]提出的SlimSAM模型摒弃了传统的SAM模型压缩方法和剪枝手段,采用交替瘦身

策略来实现模型的高效压缩。如图10所示,SlimSAM将SAM模型中的图像编码器部分分解为嵌入(Embedding)和瓶颈(Bottleneck)两个子结构,并针对二者分别进行特定的修剪(Pruning)和蒸馏(Distillation)操作,通过合理处理嵌入和瓶颈维度,实现中间特征的对齐。与传统压缩方法相比,SlimSAM通过交替优化结构维度与蒸馏目标,有效兼顾了模型的效率与知识保持能力。

4.5 性能与效率比较

现有的SAM轻量化模型主要通过重构SAM结构、知识蒸馏、模型量化和模型剪枝等方法实现效率提升。尽管这些方法在推理速度和资源消耗上取得改进,效率与性能之间的平衡仍需进一步探索。表3以2.4节中的SA-1B数据集为基准,总结了现有轻量化SAM模型在性能和效率等方面的表现。

可以看出FastSAM, MobileSAM等轻量化模型通过大幅减少参数量和计算复杂度(FLOPs),显著提升了推理速度和资源利用率,但其性能(mIoU)




图9 TinySAM架构示意图^[52]




图10 SlimSAM架构示意图^[101]

表 3 主流SAM轻量化模型性能与效率对比

模型	参数量(M)	FLOPs(G)	训练集(SA-1B)	mIoU(%)
SAM-B ^[13]	93	186	11M (100%)	73.4
SAM-L ^[13]	312	658	11M (100%)	77.7
SAM-H ^[13]	641	1368	11M (100%)	78.3
FastSAM ^[102]	68	165	220k (2%)	35.4
MobileSAM ^[50]	9.66	20	100k (1%)	62.7
EfficientSAM ^[106]	25	47	12.2M (110%)	71.2
EdgeSAM ^[56]	9.6	12	100k (1%)	65.9
SlimSAM ^[101]	9.1	12	10k (0.1%)	67.4

相较于原始SAM模型有明显下降，尤其在训练数据受限的情况下更为明显。相较而言，EfficientSAM等部分高效化模型在保持较高性能的同时实现了显著的效率提升，这表明通过精心设计的结构优化和知识蒸馏策略，可以在一定程度上缓解效率与性能之间的矛盾。此外，EdgeSAM和SlimSAM进一步压缩了模型规模，尽管它们在推理效率上表现出色，但是过度压缩也可能导致模型对复杂场景的适应能力减弱，造成一定程度的性能损失。

未来的研究应更加关注如何在不牺牲核心性能的前提下，进一步优化模型的计算效率，特别是在零样本泛化能力和复杂任务场景中的表现。这一平衡问题不仅是轻量化SAM模型发展的关键挑战，也是推动其在实际场景中实现高效部署的核心动力。

5 未来研究方向

5.1 结构轻量化设计

在当前SAM轻量化研究中，结构轻量化设计是当前最主要的研究方向。近年来，RWKV^[128]，RetNet^[129]，Mamba^[130]和KAN^[131]等高效架构通过创新的注意力机制、状态空间模型或可解释性网络结构，在保持较低计算复杂度的同时提升了模型性能，为轻量化SAM的精度-效率平衡问题提供了潜在解决方案。

5.2 硬件加速

针对不同硬件平台特性可采用分层优化策略。具体来说，在硬件架构层面，通过专用NPU/TPU加速Transformer计算，开发支持稀疏计算的定制化单元；在计算图优化方面，运用算子融合、混合精度调度及内存压缩等手段，构建面向云端与边缘设备的高效推理方案，实现模型轻量化与性能的兼顾。

5.3 数据与提示增强

在轻量化SAM的研究中，大多数模型在实现轻量化的同时不可避免地造成了一定程度的模型精

度损失。通过多样化数据增强与高效提示设计，可在减少人工交互的同时提升模型的泛化与鲁棒性，使轻量化模型在多场景任务中仍保持接近原始SAM的分割性能。

5.4 跨模型参数共享

知识协同蒸馏框架能够在保持模型性能的同时大幅降低参数量，未来可探索SAM与CLIP^[8]、DINO^[12]等视觉语言模型的参数共享与知识蒸馏框架，结合轻量级 Adapter 与多模态特征对齐，实现多任务间的高效知识复用与性能保持。

6 结束语

分割一切模型 (SAM) 的出现推动了视觉基础模型的发展，但在实际应用部署方面仍存在一些技术挑战。本文系统性梳理了SAM的整体架构与发展脉络，并围绕当前主流的轻量化方法，从高效架构替换、知识蒸馏、模型压缩与剪枝等多个维度，对代表性工作进行了归纳与分析。在此基础上，总结了当前轻量化SAM模型在图像分割、目标检测、医学图像分析和遥感图像处理等领域的典型应用，并分析了各类方法的优势与不足。从研究结论来看，当前SAM的轻量化探索主要集中在图像编码器的优化。此外，跨模态蒸馏、多尺度提示融合和自适应掩码生成等方法，也进一步拓展了模型在多样化场景下的适应能力。

尽管已有诸多进展，当前轻量化SAM模型仍面临诸如精度损失、交互提示响应能力不足、模型适应性泛化难等现实挑战。未来研究可进一步聚焦于提升模型在多场景、多模态下的泛化能力，探索更高效的端到端压缩策略与自适应蒸馏机制，构建具备可部署性与任务灵活性的轻量化视觉感知框架。

总而言之，SAM轻量化研究不仅推动了视觉基础模型在实际场景中的落地应用，也为构建高效可部署的感知系统奠定了坚实基础。未来，随着模

型设计理念的不断演化与硬件算力的持续提升, SAM及其轻量化变体有望在更广泛的应用场景中发挥更加重要的作用, 成为智能视觉系统不可或缺的核心模块。

参 考 文 献

- [1] BOMMASANI R, HUDSON D A, ADELI E, *et al.* On the opportunities and risks of foundation models[J]. arXiv preprint arXiv: 2108.07258, 2021. doi: [10.48550/arXiv.2108.07258](https://doi.org/10.48550/arXiv.2108.07258).
- [2] HAN Kai, XIAO An, WU Enhua, *et al.* Transformer in transformer[C/OL]. The 35th International Conference on Neural Information Processing Systems, 2021: 1217.
- [3] OpenAI. GPT-4 technical report[J]. arXiv preprint arXiv: 2303.08774, 2023. doi: [10.48550/arXiv.2303.08774](https://doi.org/10.48550/arXiv.2303.08774).
- [4] RADFORD A, NARASIMHAN K, SALIMANS T, *et al.* Improving language understanding by generative pre-training[J]. 2018.
- [5] CHOWDHURY A, NARANG S, DEVLIN J, *et al.* PaLM: Scaling language modeling with pathways[J]. *The Journal of Machine Learning Research*, 2023, 24(1): 240.
- [6] TOUVRON H, LAVRIL T, IZACARD G, *et al.* LLaMA: Open and efficient foundation language models[J]. arXiv preprint arXiv: 2302.13971, 2023. doi: [10.48550/arXiv.2302.13971](https://doi.org/10.48550/arXiv.2302.13971).
- [7] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, *et al.* An image is worth 16×16 words: Transformers for image recognition at scale[C/OL]. The 9th International Conference on Learning Representations, 2021.
- [8] RADFORD A, KIM J W, HALLACY C, *et al.* Learning transferable visual models from natural language supervision[C/OL]. The 38th International Conference on Machine Learning, 2021: 8748–8763.
- [9] BAO Hangbo, DONG Li, PIAO Songhao, *et al.* BEiT: BERT pre-training of image transformers[C/OL]. The 10th International Conference on Learning Representations, 2022.
- [10] HE Kaiming, CHEN Xinlei, XIE Saining, *et al.* Masked autoencoders are scalable vision learners[C]. 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition, New Orleans, USA, 2022: 16000–16009. doi: [10.1109/CVPR52688.2022.01553](https://doi.org/10.1109/CVPR52688.2022.01553).
- [11] DEVLIN J, CHANG M W, LEE K, *et al.* BERT: Pre-training of deep bidirectional transformers for language understanding[C]. The 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Minneapolis, USA, 2019: 4171–4186. doi: [10.18653/v1/N19-1423](https://doi.org/10.18653/v1/N19-1423).
- [12] ZHANG Hao, LI Feng, LIU Shilong, *et al.* DINO: DETR with improved denoising anchor boxes for end-to-end object detection[C]. The 11th International Conference on Learning Representations, Kigali, Rwanda, 2023.
- [13] KIRILLOV A, MINTUN E, RAVI N, *et al.* Segment anything[C]. 2023 IEEE/CVF International Conference on Computer Vision, Paris, France, 2023: 4015–4026. doi: [10.1109/ICCV51070.2023.00371](https://doi.org/10.1109/ICCV51070.2023.00371).
- [14] ZHANG Chunhui, LIU Li, CUI Yawen, *et al.* A comprehensive survey on segment anything model for vision and beyond[J]. arXiv preprint arXiv: 2305.08196, 2023. doi: [10.48550/arXiv.2305.08196](https://doi.org/10.48550/arXiv.2305.08196).
- [15] ZHANG Yichi, SHEN Zhenrong, and JIAO Rushi. Segment anything model for medical image segmentation: Current applications and future directions[J]. *Computers in Biology and Medicine*, 2024, 171: 108238. doi: [10.1016/j.combiomed.2024.108238](https://doi.org/10.1016/j.combiomed.2024.108238).
- [16] 王淼, 黄智忠, 何晖光, 等. 分割一切模型SAM的潜力与展望: 综述[J]. 中国图象图形学报, 2024, 29(6): 1479–1509. doi: [10.11834/jig.230792](https://doi.org/10.11834/jig.230792).
WANG Miao, HUANG Zhizhong, HE Huiguang, *et al.* Potential and prospects of segment anything model: A survey[J]. *Journal of Image and Graphics*, 2024, 29(6): 1479–1509. doi: [10.11834/jig.230792](https://doi.org/10.11834/jig.230792).
- [17] LIU Pengfei, YUAN Weizhe, FU Jinlan, *et al.* Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing[J]. *ACM Computing Surveys*, 2023, 55(9): 195. doi: [10.1145/3560815](https://doi.org/10.1145/3560815).
- [18] HU Chuanfei, XIA Tianyi, JU Shenghong, *et al.* When SAM meets medical images: An investigation of Segment Anything Model (SAM) on multi-phase liver tumor segmentation[J]. arXiv preprint arXiv: 2304.08506, 2023. doi: [10.48550/arXiv.2304.08506](https://doi.org/10.48550/arXiv.2304.08506).
- [19] WANG Chong, WAN Yajie, Li Shuxin, *et al.* SegAnyPath: A foundation model for multi-resolution stain-variant and multi-task pathology image segmentation[J]. *IEEE Transactions on Medical Imaging*, 2025, 44(10): 3924–3937. doi: [10.1109/TMI.2024.3501352](https://doi.org/10.1109/TMI.2024.3501352).
- [20] CHENG Junlong, YE Jin, DENG Zhongying, *et al.* SAM-Med2D[EB/OL]. <http://arxiv.org/abs/2308.16184v1>, 2023.
- [21] TANG Lv, XIAO Haoke, and LI Bo. Can SAM segment anything? When SAM meets camouflaged object detection[EB/OL]. <http://arxiv.org/abs/2304.04709v2>, 2023.
- [22] SHAHARABANY T, DAHAN A, GIRYES R, *et al.* AutoSAM: Adapting SAM to medical images by overloading the prompt encoder[EB/OL]. <http://arxiv.org/abs/2306.06370v1>, 2023.

- [23] DAI Haixing, MA Chong, YAN Zhiling, *et al.* SAMAUG: Point prompt augmentation for segment anything model[EB/OL]. <http://arxiv.org/abs/2307.01187v4>, 2023.
- [24] ZHANG Yichi, CHENG Yuan, and QI Yuan. SemiSAM: Exploring SAM for enhancing semi-supervised medical image segmentation with extremely limited annotations[EB/OL]. <http://arxiv.org/abs/2312.06316v1>, 2023.
- [25] OpenMMLab. MMDet-SAM[EB/OL]. https://github.com/open-mmlab/playground/blob/main/mmdet_sam/README.md, 2023.
- [26] AHMADI M, LONBAR A G, NAEINI H K, *et al.* Application of segment anything model for civil infrastructure defect assessment[J]. *Innovative Infrastructure Solutions*, 2025, 10(7): 269. doi: [10.1007/s41062-025-02073-z](https://doi.org/10.1007/s41062-025-02073-z).
- [27] LI Yaqin, WANG Dandan, YUAN Cao, *et al.* Enhancing agricultural image segmentation with an agricultural segment anything model adapter[J]. *Sensors*, 2023, 23(18): 7884. doi: [10.3390/s23187884](https://doi.org/10.3390/s23187884).
- [28] 周洁, 方振宇. 基于SAM多尺度标签优化的半监督学习遥感目标检测[J]. *微电子学与计算机*, 2026, 43(1): 65-74. doi: [10.19304/J.ISSN1000-7180.2024.0621](https://doi.org/10.19304/J.ISSN1000-7180.2024.0621).
ZHOU Jie, FANG Zhenyu. Semi-supervised remote sensing object detection based on SAM multi-scale label optimization[J]. *Microelectronics & Computer*, 2026, 43(1): 65-74. doi: [10.19304/J.ISSN1000-7180.2024.0621](https://doi.org/10.19304/J.ISSN1000-7180.2024.0621).
- [29] YU Tao, FENG Runseng, FENG Ruoyu, *et al.* Inpaint anything: Segment anything meets image inpainting[J]. arXiv preprint arXiv: 2304.06790, 2023. doi: [10.48550/arXiv.2304.06790](https://doi.org/10.48550/arXiv.2304.06790).
- [30] XIE Defeng, WANG Ruichen, MA Jian, *et al.* Edit everything: A text-guided generative system for images editing[J]. arXiv preprint arXiv: 2304.14006, 2023. doi: [10.48550/arXiv.2304.14006](https://doi.org/10.48550/arXiv.2304.14006).
- [31] WANG Teng, ZHANG Jinrui, FEI Junjie, *et al.* Caption anything: Interactive image description with diverse multimodal controls[J]. arXiv preprint arXiv: 2305.02677, 2023. doi: [10.48550/arXiv.2305.02677](https://doi.org/10.48550/arXiv.2305.02677).
- [32] YANG Jinyu, GAO Mingqi, LI Zhe, *et al.* Track anything: Segment anything meets videos[J]. arXiv preprint arXiv: 2304.11968, 2023. doi: [10.48550/arXiv.2304.11968](https://doi.org/10.48550/arXiv.2304.11968).
- [33] CHENG H K and SCHWING A G. XMem: Long-term video object segmentation with an Atkinson-Shiffrin memory model[C]. The 17th European Conference on Computer Vision, Tel Aviv, Israel, 2022: 640-658. doi: [10.1007/978-3-031-19815-1_37](https://doi.org/10.1007/978-3-031-19815-1_37).
- [34] LIU Youquan, KONG Lingdong, CEN Jun, *et al.* Segment any point cloud sequences by distilling vision foundation models[C]. The 37th International Conference on Neural Information Processing Systems, New Orleans, USA, 2023: 1617.
- [35] CEN Jiazhong, ZHOU Zanwei, FANG Jiemin, *et al.* Segment anything in 3D with NeRFs[C]. The 37th International Conference on Neural Information Processing Systems, New Orleans, USA, 2023: 1130.
- [36] 苏丽, 孙雨鑫, 苑守正. 基于深度学习的实例分割研究综述[J]. *智能系统学报*, 2022, 17(1): 16-31. doi: [10.11992/tis.202109043](https://doi.org/10.11992/tis.202109043).
SU Li, SUN Yuxin, and YUAN Shouzheng. A survey of instance segmentation research based on deep learning[J]. *CAAI Transactions on Intelligent Systems*, 2022, 17(1): 16-31. doi: [10.11992/tis.202109043](https://doi.org/10.11992/tis.202109043).
- [37] 王梓茏. 基于目标检测的遥感视觉场景理解算法研究[D]. [硕士学位论文], 中国矿业大学, 2024. doi: [10.27623/d.cnki.gzkyu.2024.003060](https://doi.org/10.27623/d.cnki.gzkyu.2024.003060).
WANG Zilong. Research on remote sensing visual scene understanding algorithms based on object detection[D]. [Master dissertation], China University of Mining and Technology, 2024. doi: [10.27623/d.cnki.gzkyu.2024.003060](https://doi.org/10.27623/d.cnki.gzkyu.2024.003060).
- [38] GHIASI G, CUI Yin, SRINIVAS A, *et al.* Simple copy-paste is a strong data augmentation method for instance segmentation[C]. 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Nashville, USA, 2021: 2918-2928. doi: [10.1109/CVPR46437.2021.00294](https://doi.org/10.1109/CVPR46437.2021.00294).
- [39] 刘思涌, 赵毅力. 微调SAM的遥感图像高效语义分割模型 DP-SAM. *中国图象图形学报*, 30(8):2884-2896. doi: [10.11834/jig.240540](https://doi.org/10.11834/jig.240540).
LIU Siyong, ZHAO Yili. DP-SAM: Efficient semantic segmentation of remote sensing images by fine-tuning SAM. *Journal of Image and Graphics*, 30(8):2884-2896. doi: [10.11834/jig.240540](https://doi.org/10.11834/jig.240540).
- [40] 吴瞳, 胡浩基, 冯洋, 等. 分割一切模型(SAM)在医学图像分割中的应用[J]. *中国激光*, 2024, 51(21): 2107102. doi: [10.3788/CJL240614](https://doi.org/10.3788/CJL240614).
WU Tong, HU Haoji, FENG Yang, *et al.* Application of segment anything model in medical image segmentation[J]. *Chinese Journal of Lasers*, 2024, 51(21): 2107102. doi: [10.3788/CJL240614](https://doi.org/10.3788/CJL240614).
- [41] HU Mingzhe, LI Yuheng, and YANG Xiaofeng. SkinSAM: Empowering skin cancer segmentation with segment anything model[J]. arXiv preprint arXiv: 2304.13973, 2023. doi: [10.48550/arXiv.2304.13973](https://doi.org/10.48550/arXiv.2304.13973).
- [42] CHAI Shurong, JAIN R K, TENG Shiyu, *et al.* Ladder fine-tuning approach for SAM integrating complementary

- network[EB/OL]. <http://arxiv.org/abs/2306.12737v1>, 2023.
- [43] 孙兴, 蔡肖红, 李明, 等. 视觉大模型SAM在医学图像分割中的应用综述[J]. 计算机工程与应用, 2024, 60(17): 1–16. doi: [10.3778/j.issn.1002-8331.2401-0136](https://doi.org/10.3778/j.issn.1002-8331.2401-0136).
- SUN Xing, CAI Xiaohong, LI Ming, *et al.* A review on the application of the vision large model SAM in medical image segmentation[J]. *Computer Engineering and Applications*, 2024, 60(17): 1–16. doi: [10.3778/j.issn.1002-8331.2401-0136](https://doi.org/10.3778/j.issn.1002-8331.2401-0136).
- [44] GAO Yifan, XIA Wei, HU Dingdu, *et al.* DeSAM: Decoupling segment anything model for generalizable medical image segmentation[EB/OL]. <http://arxiv.org/abs/2306.00499v1>, 2023.
- [45] XU Yinsong, TANG Jiaqi, MEN Aidong, *et al.* EviPrompt: A training-free evidential prompt generation method for segment anything model in medical images[EB/OL]. <http://arxiv.org/abs/2311.06400v1>, 2023.
- [46] ZHANG Jie, LI Yunxin, YANG Xubing, *et al.* RSAM-Seg: A SAM-based model with prior knowledge integration for remote sensing image semantic segmentation[J]. *Remote Sensing*, 2025, 17(4): 590. doi: [10.3390/rs17040590](https://doi.org/10.3390/rs17040590).
- [47] WANG Di, ZHANG Jing, DU Bo, *et al.* SAMRS: Scaling-up remote sensing segmentation dataset with segment anything model[C]. The 37th International Conference on Neural Information Processing Systems, New Orleans, USA, 2023: 385.
- [48] HUANG You, LAI Wenbin, JI Jiayi, *et al.* HRSAM: Efficient interactive segmentation in high-resolution images[J]. arXiv preprint arXiv: 2407.02109, 2024. doi: [10.48550/arXiv.2407.02109](https://doi.org/10.48550/arXiv.2407.02109).
- [49] CHEN Keyan, LIU Chenyang, CHEN Hao, *et al.* RSPrompter: Learning to prompt for remote sensing instance segmentation based on visual foundation model[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2024, 62: 4701117. doi: [10.1109/TGRS.2024.3356074](https://doi.org/10.1109/TGRS.2024.3356074).
- [50] ZHANG Chaoning, HAN Dongshen, QIAO Yu, *et al.* Faster segment anything: Towards lightweight SAM for mobile applications[J]. arXiv preprint arXiv: 2306.14289, 2023. doi: [10.48550/arXiv.2306.14289](https://doi.org/10.48550/arXiv.2306.14289).
- [51] XU Xiuwei, CHEN Huangxing, ZHAO Linqing, *et al.* EmbodiedSAM: Online segment any 3D thing in real time[C]. The 13th International Conference on Learning Representations, Singapore, Singapore, 2025.
- [52] SHU Han, LI Wenshuo, TANG Yehui, *et al.* TinySAM: Pushing the envelope for efficient segment anything model[C]. The 39th AAAI Conference on Artificial Intelligence, Philadelphia, USA, 2025. doi: [10.1609/aaai.v39i19.34255](https://doi.org/10.1609/aaai.v39i19.34255).
- [53] TAN Daiqing, ZANG Hao, ZHANG Xinyue, *et al.* Tongue-LiteSAM: A lightweight model for tongue image segmentation with zero-shot[J]. *IEEE Access*, 2025, 13: 11689–11703. doi: [10.1109/ACCESS.2025.3528658](https://doi.org/10.1109/ACCESS.2025.3528658).
- [54] NVIDIA-AI-IoT. nanosam: Real-time 3D segmentation framework[EB/OL]. <https://github.com/NVIDIA-AI-IOT/nanosam>, 2023.
- [55] WANG Ao, CHEN Hui, LIN Zijia, *et al.* RepViT-SAM: Towards real-time segmenting anything[J]. arXiv preprint arXiv: 2312.05760, 2023. doi: [10.48550/arXiv.2312.05760](https://doi.org/10.48550/arXiv.2312.05760).
- [56] ZHOU Chong, LI Xiangtai, LOY C C, *et al.* EdgeSAM: Prompt-in-the-loop distillation for SAM[J]. arXiv preprint arXiv: 2312.06660, 2023. doi: [10.48550/arXiv.2312.06660](https://doi.org/10.48550/arXiv.2312.06660).
- [57] WANG Guodong, CAO Yu, HU Chuanyi, *et al.* Hierarchical Distillation of SAM for Lightweight Insulator Defect Segmentation[C]. 2024 6th International Conference on Robotics, Intelligent Control and Artificial Intelligence (RICAI), Nanjing, China, 2024: 1325–1329. doi: [10.1109/RICAI64321.2024.10911250](https://doi.org/10.1109/RICAI64321.2024.10911250).
- [58] 马依拉木·木斯得克, 高雨欣, 张思拓, 等. SAM及其改进模型在图像分割中的应用综述[J]. 计算机工程, 2025, 51(8): 16–38. doi: [10.19678/j.issn.1000-3428.0070619](https://doi.org/10.19678/j.issn.1000-3428.0070619).
- MUSIDEKE M, GAO Yuxin, ZHANG Situo, *et al.* Review of application of SAM and its improved models in image segmentation[J]. *Computer Engineering*, 2025, 51(8): 16–38. doi: [10.19678/j.issn.1000-3428.0070619](https://doi.org/10.19678/j.issn.1000-3428.0070619).
- [59] MA Jun, HE Yuting, LI Feifei, *et al.* Segment anything in medical images[J]. *Nature Communications*, 2024, 15(1): 654. doi: [10.1038/s41467-024-44824-z](https://doi.org/10.1038/s41467-024-44824-z).
- [60] SHEN Qiuhong, YANG Xingyi, and WANG Xinchao. Anything-3D: Towards single-view anything reconstruction in the wild[J]. arXiv preprint arXiv: 2304.10261, 2023. doi: [10.48550/arXiv.2304.10261](https://doi.org/10.48550/arXiv.2304.10261).
- [61] YU Weihao, LUO Mi, ZHOU Pan, *et al.* MetaFormer is actually what you need for vision[C]. 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition, New Orleans, USA, 2022: 10819–10829. doi: [10.1109/CVPR52688.2022.01055](https://doi.org/10.1109/CVPR52688.2022.01055).
- [62] YU Weihao, SI Chenyang, ZHOU Pan, *et al.* MetaFormer baselines for vision[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024, 46(2): 896–912. doi: [10.1109/TPAMI.2023.3329173](https://doi.org/10.1109/TPAMI.2023.3329173).
- [63] WANG Xiaolong, GIRSHICK R, GUPTA A, *et al.* Non-local neural networks[C]. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, USA, 2018: 7794–7803. doi: [10.1109/CVPR.2018.00813](https://doi.org/10.1109/CVPR.2018.00813).
- [64] WU Fengyi, ZHANG Tianfang, LI Lei, *et al.* RPCANet:

- Deep unfolding RPCA based infrared small target detection[C]. 2024 IEEE/CVF Winter Conference on Applications of Computer Vision, Waikoloa, USA, 2024: 4809–4818. doi: [10.1109/WACV57701.2024.00474](https://doi.org/10.1109/WACV57701.2024.00474).
- [65] FU Jianhai, YU Yuanjie, LI Ningchuan, *et al.* Lite-SAM is actually what you need for segment everything[C]. The 18th European Conference on Computer Vision, Milan, Italy, 2025: 456–471. doi: [10.1007/978-3-031-72754-2_26](https://doi.org/10.1007/978-3-031-72754-2_26).
- [66] LIU Jiaji, LUO Xiaonan, WANG Dong, *et al.* MobileViTV2-based fusion of vision transformers and convolutional neural networks for underwater image enhancement[C]. 2023 13th International Conference on Information Science and Technology (ICIST), Cairo, Egypt, 2023: 195–204. doi: [10.1109/ICIST59754.2023.10367056](https://doi.org/10.1109/ICIST59754.2023.10367056).
- [67] ZHANG Tianfang, LI Lei, ZHOU Yang, *et al.* CAS-ViT: Convolutional additive self-attention vision transformers for efficient mobile applications[J]. arXiv preprint arXiv: 2408.03703, 2024. doi: [10.48550/arXiv.2408.03703](https://doi.org/10.48550/arXiv.2408.03703).
- [68] DAO T, FU D Y, ERMON S, *et al.* FlashAttention: Fast and memory-efficient exact attention with IO-awareness[C]. The 36th Annual Conference on Neural Information Processing Systems, New Orleans, USA, 2022: 16344–16359.
- [69] SHEN Yiqing, LI Jingxing, SHAO Xinyuan, *et al.* FastSAM3D: An efficient segment anything model for 3D volumetric medical images[C]. The 27th International Conference on Medical Image Computing and Computer Assisted Intervention, Marrakesh, Morocco, 2024: 542–552. doi: [10.1007/978-3-031-72390-2_51](https://doi.org/10.1007/978-3-031-72390-2_51).
- [70] SONG Yanfei, PU Bangzheng, WANG Peng, *et al.* SAM-lightening: A lightweight segment anything model with dilated flash attention to achieve 30 times acceleration[J]. arXiv preprint arXiv: 2403.09195, 2024. doi: [10.48550/arXiv.2403.09195](https://doi.org/10.48550/arXiv.2403.09195).
- [71] DAO T. FlashAttention-2: Faster attention with better parallelism and work partitioning[C]. The 12th International Conference on Learning Representations, Vienna, Austria, 2024.
- [72] GUO Jianyuan, HAN Kai, WU Han, *et al.* CMT: Convolutional neural networks meet vision transformers[C]. 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition, New Orleans, USA, 2022: 12175–12185. doi: [10.1109/CVPR52688.2022.01186](https://doi.org/10.1109/CVPR52688.2022.01186).
- [73] MEHTA S and RASTEGARI M. MobileViT: Light-weight, general-purpose, and mobile-friendly vision transformer[C]. The 10th International Conference on Learning Representations, 2022.
- [74] LEE S, CHOI J, and J. KIM H. EfficientViM: Efficient vision mamba with hidden state mixer based state space duality.[C] 2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Nashville, USA, 2025: 14923–14933. doi: [10.1109/CVPR52734.2025.01390](https://doi.org/10.1109/CVPR52734.2025.01390).
- [75] WADEKAR S N and CHAURASIA A. MobileViTv3: Mobile-friendly vision transformer with simple and effective fusion of local, global and input features[J]. arXiv preprint arXiv: 2209.15159, 2022. doi: [10.48550/arXiv.2209.15159](https://doi.org/10.48550/arXiv.2209.15159).
- [76] CAI Han, LI Junyan, HU Muyan, *et al.* EfficientViT: Lightweight multi-scale attention for high-resolution dense prediction[C]. 2023 IEEE/CVF International Conference on Computer Vision, Paris, France, 2023. doi: [10.1109/ICCV51070.2023.01587](https://doi.org/10.1109/ICCV51070.2023.01587).
- [77] SCHMIDT T and NEWCOMBEE R. Segment This Thing: Foveated Tokenization for Efficient Point-Prompted Segmentation.[C] 2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Nashville, USA, 2025: 29428–29437. doi: [10.1109/CVPR52734.2025.02740](https://doi.org/10.1109/CVPR52734.2025.02740).
- [78] LI Yanyu, HU Ju, WEN Yang, *et al.* Rethinking vision transformers for MobileNet size and speed[C]. 2023 IEEE/CVF International Conference on Computer Vision, Paris, France, 2023. doi: [10.1109/ICCV51070.2023.01549](https://doi.org/10.1109/ICCV51070.2023.01549).
- [79] ZHAO Yingwei. Efficient SAM for medical image analysis[EB/OL]. https://www.researchgate.net/publication/375895620_Efficient_SAM_for_Medical_Image_Analysis, 2023.
- [80] WU Kan, ZHANG Jinnian, PENG Houwen, *et al.* TinyViT: Fast pretraining distillation for small vision transformers[C]. The 17th European Conference on Computer Vision, Tel Aviv, Israel, 2022: 68–85. doi: [10.1007/978-3-031-19803-8_5](https://doi.org/10.1007/978-3-031-19803-8_5).
- [81] LI Pengyu, GUO Tianchu, WANG Biao, *et al.* Grid-attention: Enhancing computational efficiency of large vision models without fine-tuning[C]. The 18th European Conference on Computer Vision, Milan, Italy, 2025: 54–70. doi: [10.1007/978-3-031-72973-7_4](https://doi.org/10.1007/978-3-031-72973-7_4).
- [82] SHEN Yifan, LI Zhengyuan, and WANG Gang. Practical Region-level Attack against Segment Anything Models.[C] 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), Seattle, USA, 2024: 194–203. doi: [10.1109/CVPRW63382.2024.00024](https://doi.org/10.1109/CVPRW63382.2024.00024).
- [83] CHEN Feiyang, LUO Ziqian, ZHOU Lisang, *et al.* Comprehensive survey of model compression and speed up for vision transformers[J]. arXiv preprint arXiv: 2404.10407, 2024. doi: [10.48550/arXiv.2404.10407](https://doi.org/10.48550/arXiv.2404.10407).

- [84] HINTON G, VINYALS O, and DEAN J. Distilling the knowledge in a neural network[J]. arXiv preprint arXiv: 1503.02531, 2015. doi: [10.48550/arXiv.1503.02531](https://doi.org/10.48550/arXiv.1503.02531).
- [85] 周涛, 黄凯雯. 基于SAM引导知识蒸馏的半监督医学图像分割方法及装置[P]. 中国, 202411166303.0, 2024. ZHOU Tao and HUANG Kaiwen. SAM-guided knowledge distillation-based semi-supervised medical image segmentation method and device[P]. CN, 202411166303.0, 2024.
- [86] PATIL K D, PALANI G, and KRISHNAMURTHI G. Efficient knowledge distillation of SAM for medical image segmentation[J]. arXiv preprint arXiv: 2501.16740, 2025. doi: [10.48550/arXiv.2501.16740](https://doi.org/10.48550/arXiv.2501.16740).
- [87] ZHANG Quan, LIU Xiaoyu, LI Wei, *et al.* Distilling semantic priors from SAM to efficient image restoration models[C]. 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seattle, USA, 2024: 25409–25419. doi: [10.1109/CVPR52733.2024.02401](https://doi.org/10.1109/CVPR52733.2024.02401).
- [88] WU Jingqian, XU Rongtao, WOOD-DOUGHTY Z, *et al.* Segment anything model is a good teacher for local feature learning[J]. *IEEE Transactions on Image Processing*, 2025, 34: 2097–2111. doi: [10.1109/TIP.2025.3554033](https://doi.org/10.1109/TIP.2025.3554033).
- [89] ISRAEL U, MARKS M, DILIP R, *et al.* A foundation model for cell segmentation[J]. arXiv preprint arXiv: 2011.11004, 2023. doi: [10.48550/arXiv.2311.11004](https://doi.org/10.48550/arXiv.2311.11004).
- [90] YU Yang, XU Chen, and WANG Kai. TS-SAM: Fine-tuning segment-anything model for downstream tasks[C]. 2024 IEEE International Conference on Multimedia and Expo, Niagara Falls, Canada, 2024: 1–6. doi: [10.1109/ICME57554.2024.10688340](https://doi.org/10.1109/ICME57554.2024.10688340).
- [91] 谢政. 高效深度迁移学习与模型压缩研究[D]. [硕士学位论文], 华南理工大学, 2021. doi: [10.27151/d.cnki.ghnlh.2021.003508](https://doi.org/10.27151/d.cnki.ghnlh.2021.003508). XIE Zheng. Research on efficient deep transfer learning and model compression[D]. [Master dissertation], South China University of Technology, 2021. doi: [10.27151/d.cnki.ghnlh.2021.003508](https://doi.org/10.27151/d.cnki.ghnlh.2021.003508).
- [92] PARK G, PARK B, KIM M, *et al.* LUT-GEMM: Quantized matrix multiplication based on LUTs for efficient inference in large-scale generative language models[J]. arXiv preprint arXiv: 2206.09557, 2022. doi: [10.48550/arXiv.2206.09557](https://doi.org/10.48550/arXiv.2206.09557).
- [93] LV Chengtao, CHEN Hong, GUO Jinyang, *et al.* PTQ4SAM: Post-training quantization for segment anything[C]. 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seattle, USA, 2024. doi: [10.1109/CVPR52733.2024.01509](https://doi.org/10.1109/CVPR52733.2024.01509).
- [94] HU E J, SHEN Yelong, WALLIS P, *et al.* LoRA: Low-rank adaptation of large language models[J]. The 10th International Conference on Learning Representations, 2022.
- [95] 赵晓佳. 基于张量低秩学习的多视图聚类算法研究[D]. [硕士学位论文], 哈尔滨工业大学, 2024. doi: [10.27061/d.cnki.ghgdu.2024.000950](https://doi.org/10.27061/d.cnki.ghgdu.2024.000950). ZHAO Xiaojia. Research on multi-view clustering algorithm based on tensor low-rank learning[D]. [Master dissertation], Harbin Institute of Technology, 2024. doi: [10.27061/d.cnki.ghgdu.2024.000950](https://doi.org/10.27061/d.cnki.ghgdu.2024.000950).
- [96] ALEEM S, DIETLMIEIER J, ARAZO E, *et al.* ConvLoRA and AdaBN based domain adaptation via self-training[J]. arXiv: 2402.04964, 2024. doi: [10.48550/arXiv.2402.04964](https://doi.org/10.48550/arXiv.2402.04964).
- [97] ZHANG Kaidong and LIU Dong. Customized segment anything model for medical image segmentation[J]. arXiv preprint arXiv: 2304.13785, 2023. doi: [10.48550/arXiv.2304.13785](https://doi.org/10.48550/arXiv.2304.13785).
- [98] YUE Wenxi, ZHANG Jing, HU Kun, *et al.* SurgicalSAM: Efficient class promptable surgical instrument segmentation[C]. The 38th AAAI Conference on Artificial Intelligence, Vancouver, Canada, 2024: 6890–6898. doi: [10.1609/aaai.v38i7.28514](https://doi.org/10.1609/aaai.v38i7.28514).
- [99] 张云翔, 高圣涛. 边缘资源轻量化需求下深度神经网络双角度并行剪枝方法[J]. 沈阳工业大学学报, 2025, 47(2): 250–257. doi: [10.7688/j.issn.1000-1646.2025.02.15](https://doi.org/10.7688/j.issn.1000-1646.2025.02.15). ZHANG Yunxiang and GAO Shengpu. Dual-angle parallel pruning method for deep neural networks under requirement for lightweight edge resources[J]. *Journal of Shenyang University of Technology*, 2025, 47(2): 250–257. doi: [10.7688/j.issn.1000-1646.2025.02.15](https://doi.org/10.7688/j.issn.1000-1646.2025.02.15).
- [100] HAN Song, MAO Huizi, and DALLY W J. Deep compression: Compressing deep neural networks with pruning, trained quantization and Huffman coding[J]. arXiv preprint arXiv: 1510.00149, 2015. doi: [10.48550/arXiv.1510.00149](https://doi.org/10.48550/arXiv.1510.00149).
- [101] CHEN Zigeng, FANG Gongfan, MA Xinyin, *et al.* SlimSAM: 0.1% data makes segment anything slim[C]. The 38th International Conference on Neural Information Processing Systems, Vancouver, Canada, 2024: 39434–39461.
- [102] ZHAO Xu, DING Wenchao, AN Yongqi, *et al.* Fast segment anything[J]. arXiv preprint arXiv: 2306.12156, 2023. doi: [10.48550/arXiv.2306.12156](https://doi.org/10.48550/arXiv.2306.12156).
- [103] JOCHER G, CHAURASIA A, and QIU Jing. Yolo by ultralytics[EB/OL]. <https://github.com/ultralytics/ultralytics>, 2023.
- [104] BOLYA D, ZHOU Chong, XIAO Fanyi, *et al.* YOLACT: Real-time instance segmentation[C]. 2019 IEEE/CVF International Conference on Computer Vision, Seoul,

- Korea (South), 2019: 9157–9166. doi: [10.1109/ICCV.2019.00925](https://doi.org/10.1109/ICCV.2019.00925).
- [105] JI Shunping, WEI Shiqing, and LU Meng. Fully convolutional networks for multisource building extraction from an open aerial and satellite imagery data set[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2019, 57(1): 574–586. doi: [10.1109/TGRS.2018.2858817](https://doi.org/10.1109/TGRS.2018.2858817).
- [106] XIONG Yunyang, VARADARAJAN B, WU Lemeng, *et al.* EfficientSAM: Leveraged masked image pretraining for efficient segment anything[C]. 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seattle, USA, 2024: 16111–16121. doi: [10.1109/CVPR52733.2024.01525](https://doi.org/10.1109/CVPR52733.2024.01525).
- [107] DENG Jia, DONG Wei, SOCHER R, *et al.* ImageNet: A large-scale hierarchical image database[C]. 2009 IEEE Conference on Computer Vision and Pattern Recognition, Miami, USA, 2009: 248–255. doi: [10.1109/CVPR.2009.5206848](https://doi.org/10.1109/CVPR.2009.5206848).
- [108] PATHAK D, KRÄHENBÜHL P, DONAHUE J, *et al.* Context encoders: Feature learning by inpainting[C]. 2016 IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, USA, 2016: 2536–2544. doi: [10.1109/CVPR.2016.278](https://doi.org/10.1109/CVPR.2016.278).
- [109] VINCENT P, LAROCHELLE H, LAJOIE I, *et al.* Stacked denoising autoencoders: Learning useful representations in a deep network with a local denoising criterion[J]. *The Journal of Machine Learning Research*, 2010, 11: 3371–3408.
- [110] VARADARAJAN B, SORAN B, IANDOLA F, *et al.* SqueezeSAM: User friendly mobile interactive segmentation[J]. arXiv preprint arXiv: 2312.06736, 2023. doi: [10.48550/arXiv.2312.06736](https://doi.org/10.48550/arXiv.2312.06736).
- [111] RONNEBERGER O, FISCHER P, and BROX T. U-net: Convolutional networks for biomedical image segmentation[C]. The 18th International Conference on Medical Image Computing and Computer-Assisted Intervention, Munich, Germany, 2015: 234–241. doi: [10.1007/978-3-319-24574-4_28](https://doi.org/10.1007/978-3-319-24574-4_28).
- [112] XU Shilin, YUAN Haobo, SHI Qingyu, *et al.* RMP-SAM: Towards real-time multi-purpose segment anything[J]. arXiv preprint arXiv: 2401.10228, 2024. doi: [10.48550/arXiv.2401.10228](https://doi.org/10.48550/arXiv.2401.10228).
- [113] HE Kaiming, ZHANG Xiangyu, REN Shaoqing, *et al.* Deep residual learning for image recognition[C]. 2016 IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, USA, 2016: 770–778. doi: [10.1109/CVPR.2016.90](https://doi.org/10.1109/CVPR.2016.90).
- [114] HUANG Kaiwen, ZHOU Tao, FU Huazhu, *et al.* Learnable prompting SAM-induced knowledge distillation for semi-supervised medical image segmentation[J]. *IEEE Transactions on Medical Imaging*, 2025, 44(5): 2295–2306. doi: [10.1109/TMI.2025.3530097](https://doi.org/10.1109/TMI.2025.3530097).
- [115] ZHONG Lanfeng, LIAO Xin, ZHANG Shaoting, *et al.* Semi-supervised pathological image segmentation via cross distillation of multiple attentions[C]. The 26th International Conference on Medical Image Computing and Computer-Assisted Intervention, Vancouver, Canada, 2023: 570–579. doi: [10.1007/978-3-031-43987-2_55](https://doi.org/10.1007/978-3-031-43987-2_55).
- [116] YOU Chenyu, ZHOU Yuan, ZHAO Ruihan, *et al.* SimCVD: Simple Contrastive Voxel-Wise Representation Distillation for Semi-Supervised Medical Image Segmentation[J]. *IEEE Transactions on Medical Imaging*, 2022, 41(9): 2228–2237. doi: [10.1109/TMI.2022.3161829](https://doi.org/10.1109/TMI.2022.3161829).
- [117] LI Yunxiang, JING Bowen, LI Zihan, *et al.* nnSAM: Plug-and-play segment anything model improves nnUNet performance[J]. arXiv preprint arXiv: 2309.16967, 2023. doi: [10.48550/arXiv.2309.16967](https://doi.org/10.48550/arXiv.2309.16967).
- [118] ISENSEE F, JAEGER P F, KOHL S A A, *et al.* nnU-Net: A self-configuring method for deep learning-based biomedical image segmentation[J]. *Nature Methods*, 2021, 18(2): 203–211. doi: [10.1038/s41592-020-01008-z](https://doi.org/10.1038/s41592-020-01008-z).
- [119] XU Qing, LI Jiaxuan, HE Xiangjian, *et al.* ESP-MedSAM: Efficient self-prompting SAM for universal medical image segmentation[J]. arXiv preprint arXiv: 2407.14153v1, 2024.
- [120] ZHANG Chaoning, HAN Dongshen, ZHENG Sheng, *et al.* MobileSAMv2: Faster segment anything to everything[J]. arXiv preprint arXiv: 2312.09579, 2023. doi: [10.48550/arXiv.2312.09579](https://doi.org/10.48550/arXiv.2312.09579).
- [121] YU Lei. Efficient and robust medical image segmentation using lightweight ViT-tiny based SAM and model quantization[EB/OL]. <https://openreview.net/forum?id=clVaaD4FgD>, 2024.
- [122] LIU Zhenhua, WANG Yunhe, HAN Kai, *et al.* Post-training quantization for vision transformer[C/OL]. The 35th International Conference on Neural Information Processing Systems, 2021: 2152.
- [123] WANG Ao, CHEN Hui, LIN Zijia, *et al.* Rep ViT: Revisiting mobile CNN from ViT perspective[C]. 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seattle, USA, 2024: 15909–15920. doi: [10.1109/CVPR52733.2024.01506](https://doi.org/10.1109/CVPR52733.2024.01506).
- [124] ZHANG Zhuoyang, CAI Han, and HAN Song. EfficientViT-SAM: Accelerated segment anything model without performance loss[C]. 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, Seattle, USA, 2024: 7859–7863. doi: [10.1109/CVPRW](https://doi.org/10.1109/CVPRW)

- 63382.2024.00782.
- [125] MIYASHITA D, LEE E H, and MURMANN B. Convolutional neural networks using logarithmic data representation[J]. arXiv preprint arXiv: 1603.01025, 2016. doi: [10.48550/arXiv.1603.01025](https://doi.org/10.48550/arXiv.1603.01025).
- [126] LU Haisheng, FU Yujie, ZHANG Fan, *et al.* Efficient quantization-aware training on segment anything model in medical images and its deployment[M]. MA Jun, ZHOU Yuyin, and WANG Bo. Medical Image Segmentation Foundation Models. CVPR 2024 Challenge: Segment Anything in Medical Images on Laptop. Cham: Springer, 2025: 137–150. doi: [10.1007/978-3-031-81854-7_9](https://doi.org/10.1007/978-3-031-81854-7_9).
- [127] LIU Zechun, CHENG K T, HUANG Dong, *et al.* Nonuniform-to-uniform quantization: Towards accurate quantization via generalized straight-through estimation[C]. 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition, New Orleans, USA, 2022: 4942–4952. doi: [10.1109/CVPR52688.2022.00489](https://doi.org/10.1109/CVPR52688.2022.00489).
- [128] PENG Bo, ALCAIDE E, ANTHONY Q, *et al.* RWKV: Reinventing RNNs for the transformer era[C]. The Findings of the Association for Computational Linguistics, Singapore, 2023: 14048–14077. doi: [10.18653/v1/2023.findings-emnlp.936](https://doi.org/10.18653/v1/2023.findings-emnlp.936).
- [129] SUN Yutao, DONG Li, HUANG Shaohan, *et al.* Retentive network: A successor to transformer for large language models[J]. arXiv preprint arXiv: 2307.08621, 2023. doi: [10.48550/arXiv.2307.08621](https://doi.org/10.48550/arXiv.2307.08621).
- [130] GU A and DAO T. Mamba: Linear-time sequence modeling with selective state spaces[J]. arXiv preprint arXiv: 2312.00752, 2023. doi: [10.48550/arXiv.2312.00752](https://doi.org/10.48550/arXiv.2312.00752).
- [131] LIU Ziming, WANG Yixuan, VAIDYA S, *et al.* KAN: Kolmogorov-Arnold networks[J]. arXiv preprint arXiv: 2404.19756, 2024. doi: [10.48550/arXiv.2404.19756](https://doi.org/10.48550/arXiv.2404.19756).
- 罗一畅: 男, 博士生, 研究方向为遥感多模态大模型。
 齐析屿: 男, 博士生, 研究方向为遥感小样本目标智能解译。
 张博锐: 男, 硕士生, 研究方向为自动驾驶感知算法。
 师汉儒: 男, 博士生, 研究方向为遥感多目标跟踪。
 赵 妍: 女, 博士生, 研究方向为遥感多模态检索。
 王 磊: 男, 研究员, 研究方向为多任务遥感图像解译、多模态遥感目标跟踪。
 刘世雄: 男, 助理研究员, 研究方向为多模态大模型。

责任编辑: 马秀强

A Survey of Lightweight Techniques for Segment Anything Model

LUO Yichang^{①②③④} QI Xiyu^{①②③④} ZHANG Borui^⑤ SHI Hanru^{①②③④}
 ZHAO Yan^{①②③④} WANG Lei^{①②③} LIU Shixiong^{①②}

^①(Aerospace Information Research Institute, Chinese Academy of Sciences, Beijing 100094, China)

^②(Key Laboratory of Target Cognition and Application Technology, Beijing 100094, China)

^③(University of Chinese Academy of Sciences, Beijing 100190, China)

^④(School of Electronic, Electrical and Communication Engineering, UCAS, Beijing 100190, China)

^⑤(National University of Singapore, Singapore 119077, Singapore)

Abstract:

Objective The Segment Anything Model (SAM) demonstrates strong zero-shot generalization in image segmentation and sets a new direction for visual foundation models. The original SAM, especially the ViT-Huge version with about 637 million parameters, requires high computational resources and substantial memory. This restricts deployment in resource-limited settings such as mobile devices, embedded systems, and real-time tasks. Growing demand for efficient and deployable vision models has encouraged research on lightweight variants of SAM. Existing reviews describe applications of SAM, yet a structured summary of lightweight strategies across model compression, architectural redesign, and knowledge distillation is still absent. This review addresses this need by providing a systematic analysis of current SAM lightweight research, classifying major techniques, assessing performance, and identifying challenges and future research directions for efficient visual foundation models.

Methods This review examines recent studies on SAM lightweight methods published in leading conferences and journals. The techniques are grouped into three categories based on their technical focus. The first category, Model Compression and Acceleration, covers knowledge distillation, network pruning, and

quantization. The second category, Efficient Architecture Design, replaces the ViT backbone with lightweight structures or adjusts attention mechanisms. The third category, Efficient Feature Extraction and Fusion, refines the interaction between the image encoder and prompt encoder. A comparative assessment is conducted for representative studies, considering model size, computational cost, inference speed, and segmentation accuracy on standard benchmarks (Table 3).

Results and Discussions The reviewed models achieve clear gains in inference speed and parameter efficiency. MobileSAM reduces the model to 9.6 M parameters, and Lite-SAM reaches up to $16\times$ acceleration while maintaining suitable segmentation accuracy. Approaches based on knowledge distillation and hybrid design support generalization across domains such as medical imaging, video segmentation, and embedded tasks. Although accuracy and speed still show a degree of tension, the selection of a lightweight strategy depends on the intended application. Challenges remain in prompt design, multi-scale feature fusion, and deployment on low-power hardware platforms.

Conclusions This review provides an overview of the rapidly developing field of SAM lightweight research. The development of efficient SAM models is a multifaceted challenge that requires a combination of compression, architectural innovation, and optimization strategies. Current studies show that real-time performance on edge devices can be achieved with a small reduction in accuracy. Although progress is evident, challenges remain in handling complex scenarios, reducing the cost of distillation data, and establishing unified evaluation benchmarks. Future research is expected to emphasize more generalizable lightweight architectures, explore data-free or few-shot distillation approaches, and develop standardized evaluation protocols that consider both accuracy and efficiency.

Key words: Segment Anything Model (SAM); Lightweight model; Image segmentation; Model compression; Knowledge distillation